



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



TFG del Grado en Ingeniería
Informática

Creación de *RAG*
Documentación Técnica



Presentado por Lydia Blanco Ruiz
en Universidad de Burgos — 3 de marzo
de 2026

Tutor: Álvar Arnaiz González y César Ignacio
García Osorio

Índice general

Índice general	i
Índice de figuras	iii
Índice de tablas	v
Apéndice A Plan de Proyecto Software	1
A.1. Introducción	1
A.2. Planificación temporal	2
A.3. Estudio de viabilidad	22
Apéndice B Especificación de Requisitos	27
B.1. Introducción	27
B.2. Objetivos generales	27
B.3. Catálogo de requisitos	27
B.4. Especificación de requisitos	31
Apéndice C Especificación de diseño	55
C.1. Introducción	55
C.2. Diseño de datos	55
C.3. Diseño arquitectónico	56
C.4. Diseño procedimental	64
C.5. Diseño de interfaces	64
Apéndice D Documentación técnica de programación	77
D.1. Introducción	77
D.2. Estructura de directorios	77

D.3. Manual del programador	77
D.4. Compilación, instalación y ejecución del proyecto	77
D.5. Pruebas del sistema	77
Apéndice E Documentación de usuario	79
E.1. Introducción	79
E.2. Requisitos de usuarios	79
E.3. Instalación	79
E.4. Manual del usuario	79
Apéndice F Anexo de sostenibilización curricular	81
F.1. Introducción	81
Bibliografía	83

Índice de figuras

A.1. <i>Burndown chart</i> del <i>sprint</i> 1.	4
A.2. <i>Burndown chart</i> del <i>sprint</i> 2.	5
A.3. <i>Burndown chart</i> del <i>sprint</i> 3.	6
A.4. <i>Burndown chart</i> del <i>sprint</i> 4.	7
A.5. <i>Burndown chart</i> del <i>sprint</i> 5.	8
A.6. <i>Burndown chart</i> del <i>sprint</i> 6.	9
A.7. <i>Burndown chart</i> del <i>sprint</i> 7.	10
A.8. <i>Burndown chart</i> del <i>sprint</i> 8.	11
A.9. <i>Burndown chart</i> del <i>sprint</i> 9.	13
A.10. <i>Burndown chart</i> del <i>sprint</i> 10.	14
A.11. <i>Burndown chart</i> del <i>sprint</i> 11.	15
A.12. <i>Burndown chart</i> del <i>sprint</i> 12.	16
A.13. <i>Burndown chart</i> del <i>sprint</i> 13.	17
A.14. <i>Burndown chart</i> del <i>sprint</i> 14.	19
A.15. <i>Burndown chart</i> del <i>sprint</i> 15.	20
A.16. <i>Burndown chart</i> del <i>sprint</i> 16.	21
A.17. <i>Burndown chart</i> del <i>sprint</i> 17.	22
 B.1. Diagrama general de casos de uso.	 33
C.1. Diagrama Entidad/Relación.	57
C.2. Diagrama relacional.	58
C.3. Diagrama de la comunicación entre los principales componentes del sistema.	60
C.4. Diagrama de la gestión de peticiones del sistema.	60
C.5. Diagrama de la arquitectura lógica del sistema.	61
C.6. Prototipo de la página de inicio.	64
C.7. Prototipo de la página de inicio de sesión.	65

C.8. Prototipo de la página de registro.	65
C.9. Prototipo de la página principal.	66
C.10. Prototipo de la página del historial.	66
C.11. Prototipo de los detalles del historial.	67
C.12. Prototipo de la página de consulta.	67
C.13. Prototipo de la página de gestión de usuarios.	68
C.14. Prototipo de la página de añadir usuarios.	68
C.15. Prototipo de la página de edición del usuario.	69
C.16. Prototipo de la página de gestión de documentos.	69
C.17. Diseño de interfaz – Cabecera.	70
C.18. Diseño de interfaz – Historial de consultas.	71
C.19. Diseño de interfaz – Tabla de documentos cargados.	72
C.20. Diseño de interfaz – Interfaz de consulta al modelo.	73
C.21. Diagrama de navegabilidad por la aplicación para el administrador.	74
C.22. Diagrama de navegabilidad por la aplicación para el usuario normal.	75

Índice de tablas

A.1. Tiempo estimado de los <i>story points</i>	2
A.2. Coste total de desarrollo (TCO).	23
A.3. Coste total del proyecto.	26
B.1. CU-1 Registro de usuarios.	34
B.2. CU-2 Iniciar sesión.	35
B.3. CU-3 Cerrar sesión.	36
B.4. CU-4 Recuperar contraseña.	37
B.5. CU-5 Realizar consulta al <i>RAG</i>	38
B.6. CU-6 Consultar historial de consultas.	39
B.7. CU-7 Borrar consultas del historial.	40
B.8. CU-8 Gestión de documentos.	41
B.9. CU-9 Cargar documentos de licitaciones.	42
B.10. CU-10 Importar licitaciones automáticamente.	43
B.11. CU-11 Convertir los documentos a <i>Markdown</i>	44
B.12. CU-12 Indexar documento.	45
B.13. CU-13 Listar documentos.	46
B.14. CU-14 Consultar estado del documento.	47
B.15. CU-15 Eliminar documento.	48
B.16. CU-16 Descargar documento.	49
B.17. CU-17 Gestión de usuarios.	50
B.18. CU-18 Crear usuario.	51
B.19. CU-19 Borrar usuario.	52
B.20. CU-20 Modificar rol del usuario.	53
B.21. CU-21 Editar usuario.	54

Apéndice A

Plan de Proyecto Software

A.1. Introducción

Este documento define cómo se va a gestionar y ejecutar el desarrollo de un producto o sistema informático. Establece el alcance, los objetivos, el cronograma, los recursos, el presupuesto, los riesgos y los criterios de calidad, así como la organización del equipo y los mecanismos de seguimiento y control. En esencia, convierte una idea de software en un itinerario gestionable, con responsabilidades claras y procedimientos para controlar el progreso y los cambios.

Su importancia radica en que reduce la incertidumbre y aumenta la probabilidad de éxito académico y técnico. Permite justificar decisiones, anticipar problemas, y demostrar competencias en gestión de proyectos, ingeniería de requisitos, calidad y comunicación técnica.

En este documento se va a incluir la planificación temporal de las fases y tareas del proyecto. Para cada una se debe establecer una fecha de inicio y se debe estimar la fecha final. Para realizar esto hay que tener en cuenta el peso de cada tarea, los requisitos previos y las dependencias.

También, se va a valorar la viabilidad del proyecto. En concreto, la viabilidad económica y la legal. En la viabilidad económica se estiman los costes y los beneficios del proyecto. Mientras que en la viabilidad legal analizan las leyes y licencias que afecten al desarrollo.

A.2. Planificación temporal

Para la planificación se utiliza una metodología Scrum, aplicando iteraciones (*sprints*). Al finalizar cada *sprint* se realiza una reunión para la revisión del incremento y la planificación del siguiente. En la planificación se seleccionan y valoran las tareas (*issues*) a realizar en el siguiente *sprint*. Estas tareas se han valorado usando los *story points* de ZenHub. A las tareas que se subdividen en otras se les ha asignado solo puntos extra respecto a sus subtareas, los *story points* no se han considerado acumulativos.

Para simplificar la asignación de los *story points* se les ha asignado una estimación temporal recogida en la tabla A.1:

<i>Story Points</i>	Tiempo estimado (horas)
1	0,5
2	1
3	2
5	4
8	6
13	9
21	15
40	más de 20

Tabla A.1: Tiempo estimado de los *story points*.

Sprint 0 (11/09/2025 – 18/09/2025)

Este *sprint* marcó el comienzo del proyecto. Los objetivos fueron realizar una primera toma de contacto con los *RAG* y los *LLM*, investigando sobre qué son, cómo funcionan y qué ventajas aportan los *RAG*. También, se planteó empezar a escribir los conceptos teóricos relevantes y crear el repositorio [GitHub](https://github.com/lbr1014/TFG_RAG.git)¹ para el proyecto. Como el *sprint* se diseñó antes de la creación del repositorio, no se creó el *milestone* asociado como se ha hecho en los *sprints* posteriores. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Crear el repositorio en GitHub.
- Investigar sobre los *RAG* y *LLM*.

¹https://github.com/lbr1014/TFG_RAG.git

- Leer el capítulo 1 del libro: *A simple guide to retrieval augmented generation* [4].
- Leer el capítulo 2 del libro: *A simple guide to retrieval augmented generation* [4]
- Escribir conceptos teóricos sobre lo investigado.

Para realizar estas tareas se estimaron 6 horas de trabajo pero en realidad fueron 9. Al finalizar el *sprint* se completaron todas las tareas.

Sprint 1 (18/09/2025 – 25/09/2025)

Los objetivos del **Sprint 1**² fueron investigar sobre los *LLM* y los *RAG* y escribir la información más relevante como conceptos teóricos en la memoria. Comenzar a escribir los objetivos del proyecto y las técnicas y herramientas definidas hasta el momento, como la metodología Scrum o el repositorio. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Escribir objetivos del proyecto y técnicas y herramientas.
- Escribir conceptos teóricos.
 - Investigar sobre los *RAG* y los *LLM*.
 - Leer el capítulo 3 del libro: *A simple guide to retrieval augmented generation* [4].
 - Leer el capítulo 4 del libro: *A simple guide to retrieval augmented generation* [4].

Para realizar estas tareas se estimaron 8,5 horas de trabajo pero en realidad fueron 10. Al finalizar el *sprint* se completaron todas las tareas.

El *burndown* de este *sprint* se ilustra en la figura A.1.

Sprint 2 (25/09/2025 – 02/10/2025)

Los objetivos del **Sprint 2**³ fueron seguir investigando sobre los *LLM* y *RAG* y explicar la información relevante en los conceptos teóricos. Investigar sobre el *Web Scraping* y explicar en los anexos el plan de proyecto, en concreto la planificación temporal y los *sprints*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

²https://github.com/lbr1014/TFG_RAG/milestone/1?closed=1

³https://github.com/lbr1014/TFG_RAG/milestone/2?closed=1



Figura A.1: *Burndown chart* del *sprint* 1.

- Añadir las correcciones a la memoria.
- Completar el apartado *pipeline* de generación del apartado conceptos teóricos.
- Investigar sobre *Web Scraping*.
 - Investigar sobre HTML.
 - Investigar sobre CSS.
- Explicar el plan de proyectos en los anexos.

Para realizar estas tareas se estimaron 10 horas de trabajo pero en realidad fueron 12. Al finalizar el *sprint* se completaron todas las tareas.

El *burndown* de este *sprint* se ilustra en la figura A.2.

***Sprint* 3 (2/10/2025 – 09/10/2025)**

Los objetivos del **Sprint 3**⁴ fueron realizar un primer prototipo de *Web Scraping*, tanto en *Selenium* como en *Playwright*. Incluir en la memoria las correcciones y la información relevante. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

⁴https://github.com/lbr1014/TFG_RAG/milestone/3?closed=1




Figura A.2: *Burndown chart* del *sprint* 2.

- Añadir las correcciones a la memoria.
- Realización del comienzo de la aplicación de *web scraping*.
 - Investigar *web scraping* con Selenium.
 - Investigar *web scraping* con Playwright.
- Escribir conceptos teóricos en la memoria.
 - Leer el capítulo 5 del libro: *A simple guide to retrieval augmented generation* [4].

Para realizar estas tareas se estimaron 15 horas de trabajo pero en realidad fueron 18. Al finalizar el *sprint* se completaron todas las tareas.

El *burndown* de este *sprint* se ilustra en la figura A.3.

***Sprint* 4 (9/10/2025 – 16/10/2025)**

Los objetivos del **Sprint 4**⁵ fueron continuar realizando la aplicación de *Web Scraping*, tanto en *Selenium* como en *Playwright*, para sacar licitaciones de la página de **Contratación del Sector Público**⁶. Incluir en la memoria una

⁵https://github.com/lbr1014/TFG_RAG/milestone/4?closed=1

⁶<https://tinyurl.com/48ay5679>




Figura A.3: *Burndown chart* del *sprint* 3.

comparación entre ambas aplicaciones de *Web Scraping*. Seguir investigando sobre los *RAG*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Continuar con el *script* de *web scraping* usando Playwright.
 - Continuar con el *script* de *web scraping* usando Selenium.
 - Estudiar sobre JSON.
- Escribir conceptos teóricos en la memoria.
 - Leer el capítulo 6 del libro: *A simple guide to retrieval augmented generation* [4].

Para realizar estas tareas se estimaron 14 horas de trabajo pero en realidad fueron 18. Al finalizar el *sprint* se completaron todas las tareas.

El *burndown* de este *sprint* se ilustra en la figura A.4.

***Sprint* 5 (16/10/2025 – 23/10/2025)**

Los objetivos del **Sprint 5**⁷ fueron investigar sobre las mejoras que aporta la *API* asíncrona de *Playwright* y como se implementa. También, se

⁷https://github.com/lbr1014/TFG_RAG/milestone/5?closed=1



Figura A.4: *Burndown chart* del *sprint* 4.

planificado investigar sobre la gestión de dependencias y entornos en *Python*. Todo esto mientras se sigue investigando sobre los *RAG* y *LLM* y se escriben los aspectos más relevantes en la memoria. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Realizar código con *Playwright* asíncrono.
 - Investigar sobre la *API* asíncrona de *Playwright*.
- Investigar sobre las dependencias y los entornos en *Python*.
- Escribir conceptos teóricos en la memoria.
 - Leer más capítulo del libro: *A simple guide to retrieval augmented generation* [4].

Para realizar estas tareas se estimaron 15 horas de trabajo pero en realidad fueron 18, ya que se tuvo que reescribir parte del código realizado en los *sprints* anteriores para el *Web Scraping* debido a una actualización en la página de **Contratación del Sector Público**⁸. Este cambio afectó en mayor medida a la extracción de información de las licitaciones, ya que ha sido la página que más ha cambiado con dicha actualización. A pesar de este contratiempo al finalizar el *sprint* se completaron todas las tareas.

⁸<https://tinyurl.com/48ay5679>

Figura A.5: *Burndown chart* del *sprint* 5.

El *burndown* de este *sprint* se ilustra en la figura A.5.

***Sprint* 6 (23/10/2025 – 30/10/2025)**

Los objetivos del **Sprint 6**⁹ fueron descargar los documentos (en formato PDF) de las licitaciones de la página de **Contratación del Sector Público**¹⁰. Para descargar dichos PDF se va a usar de base el programa de *Web Scraping* del *sprint* anterior. Además, se han fijado como objetivos investigar sobre los modelos de inteligencia artificial de *Hugging Face* e instalar y probar el funcionamiento de *Ollama*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Investigar sobre *Ollama*.
- Investigar y probar modelos de inteligencia artificial de *Hugging Face*.
- Investigar sobre formas de implementar los *RAG*.
- Descargar los pdfs de las licitaciones de la la página de **Contratación del Sector Público**¹¹.
- Instalar las dependencias en *Poetry*.

⁹https://github.com/lbr1014/TFG_RAG/milestone/6?closed=1

¹⁰<https://tinyurl.com/48ay5679>

¹¹<https://tinyurl.com/48ay5679>



Figura A.6: *Burndown chart* del *sprint* 6.

Para realizar estas tareas se estimaron 12 horas de trabajo pero en realidad fueron 15, se ha usado un servidor de la UBU para descargar un `zip` con las licitaciones. Para acceder a dichas licitaciones se ha usado el archivo «`resultados_playwright_asincrono`» obtenido en el *sprint* anterior, en el cual se almacenan los enlaces a los pdfs de cada licitación. Al finalizar el *sprint* se completaron todas las tareas.

El *burndown* de este *sprint* se ilustra en la figura A.6.

***Sprint 7* (30/10/2025 – 6/11/2025)**

El objetivo principal del **Sprint 7**¹² fue investigar e implementar distintos tipos de *tokenizer*. Esto se planteó como un primer paso para la implantación total del *RAG*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Investigar sobre los *tokenizers*.
- Implementar distintos tipos de *tokenizer*.
- Comparar las implementaciones de *tokenizers*.

¹²https://github.com/lbr1014/TFG_RAG/milestone/7?closed=1



Figura A.7: *Burndown chart* del *sprint* 7.

Para realizar estas tareas se estimaron 12 horas de trabajo pero en realidad fueron 15. En este *sprint* se han llevado a cabo todas las tareas planificadas, pero sería destacable que en los *scripts* de las diversas pruebas de *tokenizers* no solo se han incluido estos. Si no que también se han incluido funciones para probar su uso, como pueden ser *prompts* y funciones para dividir los pdfs de las licitaciones.

El *burndown* de este *sprint* se ilustra en la figura A.7.

***Sprint* 8 (6/11/2025 – 13/11/2025)**

El objetivo principal del *Sprint* 8¹³ fue implementar una base de datos para el *RAG* y juntarlo con uno de los *tokenizers* ya implementados del *sprint* anterior. Además, en este *sprint* se planteó como objetivo obtener los pliegos definitivos de de la página de .

Esto se debe a que los pliegos obtenidos anteriormente no eran correctos, se trataban de resúmenes incompletos que no servían para alimentar al *RAG*. Durante el *sprint* 7, se encontraron los pliegos correctos y se fijó como objetivo del siguiente *sprint* modificar los programa de *Web Scraping* para

¹³https://github.com/lbr1014/TFG_RAG/milestone/8?closed=1



Figura A.8: *Burndown chart* del *sprint* 8.

descargarlos. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Obtener pliegos correctos.
- Estudiar sobre las distintas bases de datos.
- Implementar la base de datos.
- Explicar la comparativa de las bases de datos.

Para realizar estas tareas se estimaron 12 horas de trabajo, pero en realidad fueron 16. En este *sprint* se han llevado a cabo todas las tareas planificadas. Se ha implementado la base de datos vectorial *Qdranty* y se ha juntado con el diseño de *tokenizer* del *sprint* anterior, aunque se ha cambiado el modelo para usar el del libro *LLM Engineer's Handbook*¹⁴. Además, se han realizado los *embeddings* para poder almacenarlos en la base de datos vectorial.

El *burndown* de este *sprint* se ilustra en la figura A.8.

¹⁴<https://www.amazon.com/LLM-Engineers-Handbook-engineering-production/dp/1836200072>

Sprint 9 (13/11/2025 – 20/11/2025)

El objetivo principal del **Sprint 9**¹⁵ fue realizar un *script* que, dada una consulta, devuelva el *chunk* más parecido. Junto con este *chunk* debe devolver el nombre y el título del PDF, así como una respuesta del *LLM* basándose en dicho *chunk*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Implementar funciones que devuelvan el nombre del PDF al que pertenece el *chunk*.
- Mejorar la partición de los *chunks* añadiendo solapamiento (*overlap*).
- Obtención del fragmento del *chunk*.
- Implementar código para que el *LLM* de una respuesta a partir de una pregunta del usuario.
- Añadir al código funciones para medir los tiempos.
- Usar *loggers* en el código.

Para realizar estas tareas se estimaron 18 horas y más o menos se ha cumplido dicha estimación. En este *sprint* se han llevado a cabo todas las tareas planificadas. Se ha mejorado el código añadiendo medidas de los tiempos de ejecución e implementando el uso de *loggers*. También, se ha añadido solapamiento en los *chunks* lo que mejora la eficacia de estos. Por otro lado, se ha implementado el objetivo principal, es decir, el *script* que permite que el usuario realice una pregunta y el *LLM* conteste basándose en el *chunk* más parecido a la pregunta. Además se indica el pdf del que ha sacado la información así como el *chunk* concreto.

El *burndown* de este *sprint* se ilustra en la figura A.9.

Sprint 10 (20/11/2025 – 27/11/2025)

El objetivo principal del **Sprint 10**¹⁶ fue intentar convertir los PDF a *Markdown*. Durante la reunión de planificación del *sprint* se decidió intentarlo para ver si el conversor a *Markdown* es capaz de detectar la estructura jerárquica de los documentos PDF, ya que, si detectará las secciones y subsecciones se podrían añadir como metadatos. Esto mejoraría significativamente la relevancia de los *chunks* al poder contextualizarlos mejor. Se han valorado diversas formas de realizar la conversión, por ejemplo, desde un *OCR* vinculado a un *LLM* o directamente empleando una biblioteca de *Python*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

¹⁵https://github.com/lbr1014/TFG_RAG/milestone/9?closed=1

¹⁶https://github.com/lbr1014/TFG_RAG/milestone/10?closed=1




Figura A.9: *Burndown chart* del *sprint* 9.

- Buscar formas de automatizar la conversión a *Markdown*.
- Realizar la conversión de un pdf a *Markdown*.
 - Automatizar la conversión a *Markdown*.

Para realizar estas tareas se estimaron 10 horas, pero debido a la gran heterogeneidad de formatos de los PDF fueron más, aproximadamente unas 15. A pesar de que se han obtenido resultados significativamente mejores que en las primeras aproximaciones, no se ha conseguido ningún *Markdown* lo suficientemente bueno. Esto se debe a que cada PDF de licitaciones tiene un formato distinto y no se ha conseguido ningún *script* que detecte correctamente todas las secciones.

El *burndown* de este *sprint* se ilustra en la figura A.10.

***Sprint* 11 (27/11/2025 – 4/12/2025)**

El objetivo principal del *Sprint* 11¹⁷ fue intentar implementar un *script* que basándose en los resultados obtenidos del anterior sea capaz de detectar correctamente las secciones de los PDF. Además, se propuso comenzar a investigar sobre el funcionamiento de *Flask*. Ya que esta aplicación se va a

¹⁷https://github.com/lbr1014/TFG_RAG/milestone/11?closed=1

Figura A.10: *Burndown chart* del *sprint* 10.

utilizar en el proyecto para realizar una *web* para realizar las consultas al *LLM*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Probar nuevos OCR para la conversión de los PDF a *Markdown*.
- Investigar sobre *Flask*.

Para realizar estas tareas se estimaron 8 horas. Al final se emplearon cerca de 12 horas debido al mismo problema del *sprint* anterior, que no se ha conseguido implementar un *script* capaz de detectar correctamente todas las secciones.

El *burndown* de este *sprint* se ilustra en la figura A.11.

***Sprint* 12 (4/12/2025 – 15/01/2026)**

El objetivo principal del **Sprint 12**¹⁸ fue comenzar a realizar la página *web* con *Flask* y comenzar a definir los casos de uso del proyecto. Este *sprint* fue más largo que el resto ya que coincidió con la semana de exámenes finales del primer cuatrimestre y las navidades. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

¹⁸https://github.com/lbr1014/TFG_RAG/milestone/12?closed=1



Figura A.11: *Burndown chart* del *sprint* 11.

- Definir los casos de uso.
 - Identificar los casos de uso del proyecto.
 - Identificar los requisitos del proyecto.
- Comenzar la página *web*.
- Hacer la gestión básica de usuarios.
- Implementar la gestión de usuarios para los administradores.
- Hacer los *test* para la gestión de usuarios de la *web*.

Para realizar estas tareas se estimaron 28 horas de trabajo. Al final se emplearon más de 35 horas, debido principalmente a que la tarea «Comenzar la página *web*» llevó más tiempo del planificado. Esta tarea consistió en realizar la estructura básica de la *web*, la cual finalmente se dividió en *blueprints* para que tuviese mejor escalabilidad. Comprender el funcionamiento de los *blueprints* y saber implementarlos aumentó significativamente el tiempo de desarrollo de la estructura de la *web*.

El *burndown* de este *sprint* se ilustra en la figura A.12.

Figura A.12: *Burndown chart* del *sprint* 12.

Sprint 13 (15/01/2025 – 22/01/2026)

El objetivo principal del **Sprint 13**¹⁹ fue completar las funcionalidades de la *web* permitiendo que los administradores puedan cargar documentos, de forma manual o automática (mediante *web scraping*). El sistema gestionará estos documentos para extraer de ellos los *embeddings* necesarios para el *RAG*. Además, se marcó como objetivo incluir la interfaz para realizar las consultas al *LLM*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Añadir casos de uso.
- Incluir una clase consulta.
- Añadir la funcionalidad carga de documentos.
- Mostrar historial de consultas.
- Implementar las consultas en la *web Flask*.
- Juntar el *web scraping* con la carga de documentos de la *web*.
- Realizar la interfaz de las consultas.
- Poner la clave secreta como variable de entorno.

¹⁹https://github.com/lbr1014/TFG_RAG/milestone/13?closed=1



Figura A.13: *Burndown chart* del *sprint* 13.

Para realizar estas tareas se estimaron 28,5 horas de trabajo. Al final del *sprint* se cumplieron todas las tareas más o menos en el plazo esperado.

El *burndown* de este *sprint* se ilustra en la figura A.13.

***Sprint* 14 (22/01/2025 – 29/01/2026)**

El objetivo principal del **Sprint 14**²⁰ fue convertir los procesos de *web scraping* y de actualización de la base de datos vectorial a modo asíncrono. En la reunión se decidió priorizar este cambio, ya que la implementación anterior, en modo síncrono, tardaba mucho tiempo y bloqueaba la web para el usuario. Por otro lado, se decidió continuar desarrollando la documentación, concretamente los anexos. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Cambios en las clases de la aplicación.
 - Cambios en la clase documentos.
- Escribir en los anexos el diseño de datos.
 - Realizar el diagrama relacional.

²⁰https://github.com/lbr1014/TFG_RAG/milestone/14?closed=1

- Realizar el diagrama Entidad/Relación.
- Aplicar correcciones a los anexos.
- Realizar el diagrama de casos de uso.
- Diseño de interfaces.
- Cambio de funcionalidades a modo asíncrono.
- Incluir mensajes de *feedback* para el usuario.
- Incluir las clases **Chunk** y **Embedding**.
- Aplicar cambios en el código para integrar correctamente las nuevas clases.
- Crear tabla **ConsultaChunk**.
- Revisar y corregir código usando *SonarCloud*.
- Hacer que el *LLM* use más de un *chunk* para responder.

Para realizar estas tareas se estimaron 50 horas de trabajo. Al final del *sprint* se cumplieron todas las tareas. El tiempo final dedicado fue más o menos el estimado. A pesar de que algunas tareas (como las de corregir el código usando *SonarCloud* y las de cambiar las funcionalidades a modo asíncrono) se retrasaron, hubo otras como las de realizar los diagramas que se adelantaron.

El *burndown* de este *sprint* se ilustra en la figura A.14.

Sprint 15 (29/01/2025 – 05/02/2026)

El objetivo principal del **Sprint 15**²¹ fue levantar mi aplicación *Flask* usando un contenedor *docker*. En la reunión se decidió implementar un *docker* ya que mejora la potabilidad, la ligereza y el aislamiento de la aplicación. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Implementar un *docker* para la aplicación *Flask*.
 - Estudiar como desplegar la aplicación *web*.
 - Arreglar la indexación de documentos para usar el *docker*.
 - Arreglo de *Web Scraping* para evitar fallos por perdida de conexión.
- Empezar a escribir la viabilidad económica.
- Completar los *test* unitarios realizados previamente.
- Realiza *test* unitarios para las nuevas clases.

²¹https://github.com/lbr1014/TFG_RAG/milestone/15?closed=1




Figura A.14: *Burndown chart* del *sprint* 14.

Para realizar el *sprint* se estimaron 34 horas de trabajo. Al final de este *sprint* se invirtieron unas 40 horas, pero, no se completaron todas las tareas, quedando incompletas las tareas «Completar los *test* unitarios realizados previamente» y «Realiza *test* unitarios para las nuevas clases». Esto se debió a que la implementación de *docker* llevo más tiempo del esperado por fallos en la conexión con el módulo de *qdrant*. Las tareas incompletas se van a llevar a cabo en el siguiente *sprint*.

El *burndown* de este *sprint* se ilustra en la figura A.15.

***Sprint* 16 (05/02/2025 – 12/02/2026)**

El objetivo principal del **Sprint 16**²² fue incluir el uso de *Nginx* para levantar la aplicación *web* en el servidor integrándolo con la implementación de *Gunicorn* del *sprint* anterior. Además, se fijó como objetivo explicar en la memoria algunos trabajos relacionados. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Incluir trabajos relacionados en la memoria.
- Incluir imágenes en la memoria.

²²https://github.com/lbr1014/TFG_RAG/milestone/16?closed=1

Figura A.15: *Burndown chart* del *sprint* 15.

- Correcciones documentación.
- Completar algunos de los *tests* unitarios realizados previamente.
- Realizar *tests* unitarios para las nuevas clases.
- Mejoras en el *docker*.
- Incluir *Nginx* en la aplicación *Flask*.

Para realizar el *sprint* se estimaron 34 horas de trabajo. Al finalizar el *sprint* se realizaron todas las tareas, y de manera general respetando la planificación temporal. En el caso de la tarea «Incluir trabajos relacionados en la memoria» se estimó que se iba a realizar en 4 horas pero finalmente fueron unas 6 horas, ya que, se realizó una comparativa entre ellos y con el proyecto que se está llevando a cabo en este TFG.

El *burndown* de este *sprint* se ilustra en la figura A.16.

***Sprint* 17 (12/02/2025 – 19/02/2026)**

El objetivo principal del *Sprint* 17²³ fue incluir que la aplicación pueda mandar correos a los usuarios, concretamente para avisar cuando acaban de ejecutarse los procesos largos (como el *web scraping* o la actualización de la

²³https://github.com/lbr1014/TFG_RAG/milestone/17?closed=1




Figura A.16: *Burndown chart* del *sprint* 16.

base de datos vectorial) y para la recuperación de la contraseña cuando se le ha olvidado. También, se siguieron implementando los *tests* unitarios de la aplicación para cubrir el *coverage*. Para llevar a cabo estos objetivos se plantearon las siguientes tareas:

- Correo cuando finalicen las tareas largas.
 - Incluir recuperación de contraseña.
 - Investigar como se pueden mandar correos automáticos desde *Flask*.
- Completar *tests* y generar el informe del *coverage*.
- Incluir conversión a *markdown* en la aplicación.
- Botón cancelar consulta.

Para realizar el *sprint* se estimaron 24 horas de trabajo. Al finalizar el *sprint* se realizaron todas las tareas invirtiendo unas 30 horas. Esto se debió a que la realización de los *tests* llevó más tiempo del planificado. Sobre todo, aquellos los de las clases concurrentes y aquellos para los que se necesitaba entorno con bases de datos.

El *burndown* de este *sprint* se ilustra en la figura A.17.




Figura A.17: *Burndown chart* del *sprint* 17.

***Sprint* 18 (19/02/2025 – 26/02/2026)**

***Sprint* 19 (26/02/2025 – 5/03/2026)**

A.3. Estudio de viabilidad

El estudio de viabilidad es un análisis detallado que se realiza antes de iniciar un proyecto. Sirve para determinar la rentabilidad de ese proyecto, es decir, si se puede hacer realidad. Para ello se analiza si es económicamente rentable (sección A.3.1) y legalmente viable (sección A.3.2).

Viabilidad económica

Para analizar la viabilidad económica se ha seguido el coste total de propiedad (TCO) [5]. El TCO consiste en identificar y estimar todos los costes asociados al ciclo de vida de un producto tecnológico, no solo los costes directos de su adquisición, sino también los derivados de su operación, mantenimiento y uso a lo largo del tiempo. De esta forma, se obtiene una visión global y realista del impacto económico del sistema. Los costes considerados vienen recogidos en la tabla A.2.

Componentes	Componentes del costo
Adquisición <i>hardware</i>	Precio de compra del equipo <i>hardware</i> . Se debe tener en cuenta los ordenadores, terminales, almacenamiento e impresoras.
Adquisición <i>software</i>	Compra de licencias y <i>software</i> para cada usuario.
Instalación	Coste para instalar los ordenadores y el <i>software</i> .
Capacitación	Coste de entrenamiento de los especialistas y de los usuarios finales.
Soporte	Coste para dar soporte técnico continuo.
Mantenimiento	Coste para mantener y actualizar el <i>hardware</i> y <i>software</i> .
Infraestructura	Coste por adquirir, mantener y dar soporte a la infraestructura relacionada. Incluye las redes y el equipo especializado.
Tiempo inactivo	Coste de pérdidas de productividad debido a fallos de <i>hardware</i> o <i>software</i> . Estos fallos provocan que el sistema no este disponible.
Espacio y energía	Coste de bienes y servicios públicos para alojar y proveer energía para la tecnología.

Tabla A.2: Coste total de desarrollo (TCO).

Para llevar a cabo el estudio de la viabilidad económica se va a considerar que el trabajo llevado a cabo por la alumna lo ha realizado un desarrollador contratado durante los 9 meses que ha durado el proyecto. Si se supone un escenario empresarial real en España y se toma como referencia el **Salario Mínimo Interprofesional (SMI) de 2024²⁴**, el salario mínimo anual es de 15 876 €, es decir, 1 134 € al mes (se divide en 14 pagas). Además, a este salario hay que añadirle los gastos por la cotización a la **Seguridad**

²⁴<https://www.boe.es/buscar/doc.php?id=B0E-A-2024-2251>

Social²⁵. Normalmente la cotización es del 28,30 %, de los cuales 23,60 % se corresponden con gastos de la empresa. Por lo cual el gasto por la contratación del desarrollado sería:

$$1\,134 \frac{\text{€}}{\text{meses}} \cdot 1,236 \cdot 9 \text{ meses} = 12\,614,62 \text{ €}$$

Respecto a la adquisición de *hardware* no ha sido necesaria la adquisición de *hardware* específico adicional. El sistema *RAG* se ha implementado de forma que se pueda ejecutar en entornos estándares, sin requerir servidores dedicados ni equipamiento especializado. El desarrollo y las pruebas se han realizado utilizando mi equipo personal y servidores ya disponibles en la universidad. El equipo utilizado ha sido un *Victus by HP Gaming Laptop 16-r0xxx*²⁶. El coste de adquisición del portátil fueron unos 1 200 €. Considerando un periodo de amortización de 5 años, el coste amortizado correspondiente al proyecto con una duración de 9 meses (del 11 de septiembre al 11 junio) sería:

$$\left(\frac{1\,200 \text{ €}}{5 \text{ años} \cdot 12 \text{ meses}} \right) \cdot 9 \text{ meses} = 180 \text{ €}$$

Además, se ha usado el servidor *beta*²⁷ de la universidad. Aunque el servidor no se ha considerado un gasto de *hardware* ya que se ha considerado que se amortizaba en 5 años y ya tienen 9.

Respecto a la adquisición de *software* la mayor parte del *software* utilizado en el proyecto es de código abierto y de uso gratuito, como *Python*, *Flask*, *Qdrant*, *PostgreSQL*, *Docker* o las librerías de *Hugging Face*. Estas herramientas no implican un coste directo de licencia. Por lo cual el único gasto que debe considerarse en este apartado es la adquisición de la licencia de *Windows*²⁸ con un coste de unos 145 €. Se considera una amortización de 5 años, por lo cual para los 9 meses del proyecto:

$$\left(\frac{145 \text{ €}}{5 \text{ años} \cdot 12 \text{ meses}} \right) \cdot 9 \text{ meses} = 21,75 \text{ €}$$

Por otro lado en el proyecto no ha habido costes indirectos asociados a servicios de terceros como pueden ser las API o modelos en la nube, ya que se han elegido alternativas gratuitas.

²⁵<https://www.seg-social.es/wps/portal/wss/internet/Trabajadores/CotizacionRecaudacionTrabajadores/36537>

²⁶https://support.hp.com/es-es/document/ish_7878690-7886844-16

²⁷<https://www.gigabyte.com/es/Enterprise/Server-Motherboard/MW51-HP0-rev-1x>

²⁸<https://www.microsoft.com/es-es/d/windows-11-home/dg7gmgf0krt0/000P>

Los costes de instalación incluyen el tiempo invertido en la configuración del entorno de desarrollo, instalación de dependencias, despliegue del sistema con *Docker* y configuración de las bases de datos. Este tiempo debe considerarse como un coste laboral. Se estima que en estas tareas se ha invertido un 20 % del tiempo total del proyecto. Por lo cual teniendo en cuenta que el coste laboral del desarrollador ha sido de 12 614,62 € el de los costes de instalación se corresponde:

$$12\,614,62\,€ \cdot 0,20 = 2\,522,92\,€$$

Respecto a los costes de capacitación, se ha requerido una fase importante de aprendizaje en tecnologías como *RAG*, bases de datos vectoriales, modelos *LLM*, *web scraping* y despliegue *web*. Este tiempo de formación constituye un coste indirecto de capital humano. Se estima que aproximadamente un 25 % del tiempo total del proyecto ha sido dedicado a tareas de aprendizaje. Por lo cual, el coste de capacitación ha sido:

$$12\,614,62\,€ \cdot 0,25 = 3\,153,66\,€$$

El soporte durante la ejecución del proyecto ha sido llevado a cabo por los tutores. Se han llevado a cabo reuniones (*sprints*) para la revisión de decisiones y la resolución de problemas. Han sido necesarias unas 28 reuniones a lo largo del proyecto de aproximadamente una hora cada una. Además, al tiempo invertido para el soporte técnico, debe sumarse el tiempo para llevar a cabo las revisiones de la memoria, los anexos y del código. En total se estima que los tutores han invertido unas 100 horas en el proyecto cada uno. Se va a suponer que su sueldo es de 20 € la hora al mes sería:

$$20 \frac{€}{\text{hora}} \cdot 7 \frac{\text{horas}}{\text{días}} \cdot 5 \frac{\text{días}}{\text{semana}} \cdot 4 \frac{\text{semanas}}{\text{mes}} = 2\,800 \frac{€}{\text{mes}}$$

Por lo cual el gasto en soporte sería:

$$20 \frac{€}{\text{hora}} \cdot 200 \text{ horas} = 4\,000\,€$$

En el mantenimiento se incluye corrección de errores, adaptación a cambios en las fuentes de obtención de datos (como las modificaciones en la *web* de contratación pública) y actualización de dependencias. A lo largo del proyecto se han producido varias modificaciones del código motivadas por cambios externos, por lo cual ha sido necesario dedicar tiempo periódico al mantenimiento correctivo y evolutivo. Este coste se traduce en un 5 % del

tiempo total de desarrollo del proyecto. Por lo cual el coste de mantenimiento ha sido:

$$12\,614,62\text{ €} \cdot 0,05 = 630,73\text{ €}$$

Respecto a la infraestructura necesaria para el proyecto, se basa en servicios de red, bases de datos y servidores locales. Se han utilizado infraestructuras universitarias (el servidor cuya amortización ya se ha tenido en cuenta en el apartado de adquisición de *hardware*) y servicios gratuitos, por lo cual no es necesario sumar gastos e infraestructuras al proyecto.

El tiempo inactivo se corresponde al impacto económico que suponen los periodos en los que el sistema no está operativo o no puede utilizarse de forma eficiente.

Finalmente, deben considerarse los costes asociados al espacio físico del trabajo y al consumo de energía del equipo. Se ha considerado que para llevar a cabo el proyecto se ha gastado una media de 80 € mensuales de electricidad, como el proyecto ha durado 9 meses, el coste total sería:

$$80 \frac{\text{€}}{\text{meses}} \cdot 9 \text{ meses} = 720\text{ €}$$

Los costes totales del proyecto vienen desglosados en la siguiente tabla [A.3](#)

Componentes	Estimación (euros)
Adquisición <i>hardware</i>	180
Adquisición <i>software</i>	21,75
Instalación	2 522,92
Capacitación	3 153,66
Soporte	4 000
Mantenimiento	630,73
Infraestructura	0
Tiempo inactivo	0
Espacio y energía	720
Coste total del proyecto	11 229

Tabla A.3: Coste total del proyecto.

Viabilidad legal

Apéndice B

Especificación de Requisitos

B.1. Introducción

B.2. Objetivos generales

Los objetivos generales que se buscan cumplir con este proyecto son:

- Desarrollar un sistema basado en Generación Aumentada por Recuperación (*RAG*) que permita realizar consultas sobre licitaciones del sector público, enriqueciendo las respuestas mediante información documental relevante.
- Automatizar la recopilación, procesamiento e indexación de documentos de licitaciones, de forma que puedan ser integrados eficientemente en una base de datos vectorial.
- Facilitar la consulta de la información de las licitaciones mediante una aplicación web intuitiva y accesible para usuarios autenticados.
- Mejorar la comprensión y análisis de la información administrativa y técnica contenida en las licitaciones.

B.3. Catálogo de requisitos

A continuación se van a definir los requisitos del proyecto, tanto los funcionales como los no funcionales.

Requisitos funcionales

- **RF-1** Gestión de documentos: el sistema debe permitir que el administrador gestione los documentos de licitaciones del sistema.
 - **RF-1.1** Inserción de documentos: el sistema debe permitir cargar documentos de licitaciones con el objetivo de construir y actualizar la base de datos vectorial.
 - **RF-1.2** Listado de documentos cargados: el sistema debe permitir ver los documentos cargados y sus metadatos.
 - **RF-1.3** Borrado de documentos: el sistema debe permitir borrar los documentos cargados.
 - **RF-1.4** Descarga de documentos: el sistema debe permitir descargar los documentos cargados.
- **RF-2** Procesado de los documentos: el sistema debe procesar de manera automática los documentos introducidos para prepararlos para que el *RAG* pueda usarlos.
 - **RF-2.1** Extracción de información: el sistema debe extraer automáticamente el contenido textual de los documentos introducidos, ignorando páginas o documentos sin texto extraíble.
 - **RF-2.2** Conversión del contenido: el sistema debe transformar el texto extraído a un formato homogéneo, concretamente a *markdown* para que sea más fácil su procesamiento.
 - **RF-2.2.1** Conservar estructura básica: el sistema debe conservar la estructura básica del texto siempre que sea posible (secciones, títulos, saltos de línea, párrafos, etc).
 - **RF-2.3** Limpieza y normalización del texto: el sistema debe limpiar y normalizar el texto que se extrae de los documentos.
 - **RF-2.3.1** Eliminar caracteres: el sistema debe eliminar los caracteres irrelevantes o problemáticos.
 - **RF-2.3.2** Normalización: el sistema debe normalizar los espacios, saltos de línea y formatos inconsistentes.
- **RF-3** Segmentación en *chunks*: el sistema debe dividir los documentos ya procesados en fragmentos de texto (*chunks*) adecuados para el modelo de *embeddings*.
 - **RF-3.1** Tamaño: el sistema debe segmentar el texto respetando un máximo de tamaño medido en número de *tokens* para evitar errores.
 - **RF-3.2** Solapamiento: el sistema debe aplicar solapamiento entre *chunks* para preservar el contexto.
 - **RF-3.3** Contexto: cada *chunk* debe tener una referencia al documento original y a su posición dentro de él.

- **RF-4** Generación de *embeddings*: el sistema debe generar representaciones vectoriales (*embeddings*) para cada *chunk*.
- **RF-5** Persistencia en base de datos vectorial: el sistema debe almacenar los *chunks* y sus *embeddings* en una base de datos vectorial.
 - **RF-5.1** Almacenar *chunks*: el sistema debe almacenar el contenido textual de cada *chunk*.
 - **RF-5.2** Almacenar *embeddings*: el sistema debe almacenar el *embedding* asociado a cada *chunk*.
 - **RF-5.3** Almacenar metadatos: el sistema debe almacenar metadatos relevantes como el nombre del archivo, el título y el segmento incluido en el *chunk*.
 - **RF-5.4** Actualización: el sistema debe permitir la actualización o recreación de la colección vectorial en el caso de incluir documentos nuevos.
 - **RF-5.5** Eliminar: el sistema debe permitir borrar los *chunks* y *embeddings* de la base de datos vectorial.
- **RF-6** Recuperación de información por similitud: el sistema debe recuperar información relevante a partir de las consultas de los usuarios.
 - **RF-6.1** Generación de *embedding*: el sistema debe generar el *embedding* de la consulta del usuario.
 - **RF-6.2** Búsqueda por similitud: el sistema debe realizar una búsqueda por similitud en la base de datos vectorial.
- **RF-7** Construcción del *prompt* con contexto: el sistema debe construir un *prompt*, para alimentar al *LLM*, que incluya los *chunks* recuperados, la pregunta del usuario e instrucciones de uso del contexto.
- **RF-8** Generación de respuestas mediante un *LLM*: el sistema debe enviar el *prompt* generado a un modelo *LLM* y mostrar la respuesta de dicho modelo al usuario.
- **RF-9** Trazabilidad de respuesta: el sistema debe devolver junto con la respuesta los metadatos del documento origen y los *chunks* empleados para la generación de la respuesta.
- **RF-10** Gestión de usuarios: el sistema debe permitir la gestión de usuarios a través de la aplicación web.
 - **RF-10.1** Registros y autenticación: el sistema debe permitir el registro y autenticación de los usuarios.
 - **RF-10.2** Sesiones: el sistema debe gestionar las sesiones de los usuarios de forma segura.
 - **RF-10.3** Roles: el sistema debe permitir asignar a los usuarios el rol de administradores o usuarios normales.

- **RF-10.4** Administradores: los administradores deben poder añadir usuarios, eliminarlos y cambiar su rol.
- **RF-10.5** Edición de datos de usuario: los usuarios deben poder editar sus datos.
- **RF-10.6** Recuperación de contraseña: los usuarios deben poder cambiar su contraseña utilizando su correo.
- **RF-11** Interfaz de consultas: los usuarios autenticados podrán realizar consultas y ver las respuestas del sistema.
 - **RF-11.1** Historial de consultas: los usuarios podrán ver su historial de consultas.
 - **RF-11.2** Borrar consultas: los usuarios podrán borrar consultas del historial.
- **RF-12** Importación automática de licitaciones: el sistema debe permitir al administrador importar de manera automática las licitaciones mediante *web scraping*.
 - **RF-12.1** Descarga y almacenamiento: el sistema debe descargar y almacenar los documentos obtenidos, así como sus metadatos.
 - **RF-12.2** Gestión de errores y duplicados: el sistema debe continuar aunque la descarga de algún documento falle. Debe registrar los errores y evitar duplicados.

Requisitos no funcionales

- **RNF-1** Reproducibilidad: el proyecto debe ejecutarse en un entorno reproducible.
- **RNF-2** Rendimiento: el sistema debe ser capaz de procesar los documentos sin intervención manual. Además, el sistema tiene que responder en un tiempo razonable.
- **RNF-3** Robustez ante errores: el sistema debe continuar ejecutándose ante fallos esperables en datos, red o servicios externos.
 - **RNF-3.1** Documentos corruptos: el sistema debe saltarse los documentos corruptos o sin texto extraíble y continuar con el resto de documentos.
 - **RNF-3.2** *Timeouts*: el sistema debe manejar los *timeouts* del *LLM* devolviendo mensajes controlados al usuario.
- **RNF-4** Trazabilidad técnica: el sistema debe realizar *logs* de carga de modelo, lectura de los PDF, *chunking*, *embeddings*, guardado y consulta.

- **RNF-5** Seguridad: el sistema debe gestionar de forma segura la información sensible de los usuarios y el acceso a la aplicación.
 - **RNF-5.1** Contraseñas: las contraseñas deben almacenarse encriptadas.
 - **RNF-5.2** Control de acceso por roles: las funciones administrativas deben estar protegidas por rol para que solo las pueda realizar el administrador.
 - **RNF-5.3** Protección de secretos: las claves sensibles no deben estar públicas en el repositorio.
- **RNF-6** Usabilidad: la interfaz debe permitir a los usuarios realizar las consultas y ver el historial de manera sencilla. Además, los textos deben ser legibles.
- **RNF-7** Calidad del *software*: debe existir un conjunto de pruebas que asegure el correcto funcionamiento del programa.
- **RNF-8** Disponibilidad: la web debe garantizar un nivel de disponibilidad adecuado que permita a los usuarios acceder a la aplicación y realizar consultas.
- **RNF-9** Recuperación y tolerancia a fallos: el sistema debe disponer de mecanismos que permitan la recuperación de información y la restauración del servicio tras fallos, garantizando la integridad de los datos.
- **RNF-10** Evitar alucinaciones: el sistema no debe responder cuando no haya contexto relevante suficiente.
- **RNF-11** Calidad de las respuestas del *LLM*: el sistema debe llevar a cabo un control de calidad de las respuestas que da el *LLM* a las consultas del usuario.

B.4. Especificación de requisitos

Los actores del sistema son:

- **Usuario anónimo**: usuario que no ha iniciado sesión (solo puede registrarse y autenticarse)
- **Usuario autenticado**: usuario que puede acceder a la aplicación sus acciones en al aplicación cambiarán dependiendo de su rol.
 - **Usuario normal**: usuario autenticado que puede consultar el *RAG* y ver su historial
 - **Usuario administrador**: usuario autenticado con permisos de gestión de usuarios y de carga y actualización documental

- **Sistema:** es el encargado del procesamiento, *chunking*, *embeddings*, guardado y consulta.

Los casos de uso definidos para el proyecto son:

- **CU-1** Registro de usuarios (ver tabla B.1).
- **CU-2** Iniciar sesión (ver tabla B.2).
- **CU-3** Cerrar sesión (ver tabla B.3).
- **CU-4** Recuperar contraseña (ver tabla B.4).
- **CU-5** Realizar consulta al *RAG* (ver tabla B.5).
- **CU-6** Consultar historial de consultas (ver tabla B.6).
- **CU-7** Borrar consultas del historial (ver tabla B.7).
- **CU-8** Gestión de documentos (ver tabla B.8).
- **CU-9** Cargar documentos de licitaciones (ver tabla B.9).
- **CU-10** Importar licitaciones automáticamente (ver tabla B.10).
- **CU-11** Convertir los documentos a *Markdown* (ver tabla B.11).
- **CU-12** Indexar documento (ver tabla B.12).
- **CU-13** Listar documentos (ver tabla B.13).
- **CU-14** Consultar estado del documento (ver tabla B.14).
- **CU-15** Eliminar documento (ver tabla B.15).
- **CU-16** Descargar documento (ver tabla B.16).
- **CU-17** Gestión de usuario (ver tabla B.17).
- **CU-18** Crear usuario (ver tabla B.18).
- **CU-19** Borrar usuario (ver tabla B.19).
- **CU-20** Modificar rol del usuario (ver tabla B.20).
- **CU-21** Editar usuario (ver tabla B.21).

El diagrama de los casos de uso se muestra en la imagen B.1.




Figura B.1: Diagrama general de casos de uso.

CU-1	Registro de usuarios
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.1
Descripción	Permite crear una cuenta en la aplicación web.
Precondición	Que el usuario no esté autenticado.
Acciones	1. El usuario accede a «Registro». 2. El usuario introduce el nombre, <i>email</i> y contraseña. 3. El sistema valida el formato y que el <i>email</i> no esté duplicado. 4. El sistema almacena el usuario con la contraseña encriptada. 5. El sistema confirma el registro. 6. El sistema crea la sesión y redirige a la página de consultas.
Postcondición	Cuenta creada y usuario autenticado
Excepciones	1. Tiene algún campo vacío $\Rightarrow$ Mostrar error de campo obligatorio. 2. El <i>email</i> ya existe $\Rightarrow$ Mostrar error de <i>email</i> duplicado. 3. El <i>email</i> no cumple la validación $\Rightarrow$ Mostrar error de <i>email</i> inválido. 4. La contraseña no cumple la política $\Rightarrow$ Mostrar error de contraseña poco segura. 5. Las contraseñas no coinciden $\Rightarrow$ Mostrar error de contraseñas distintas. 6. El nombre tiene menos de 2 caracteres $\Rightarrow$ Mostrar error de nombre demasiado corto.
Importancia	Alta.

Tabla B.1: CU-1 Registro de usuarios.

CU-2	Iniciar sesión
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.1 , RF-10.2
Descripción	Autentifica al usuario y abre una sesión segura.
Precondición	Que el usuario esté registrado y no esté autenticado.
Acciones	1. El usuario accede a «Iniciar sesión». 2. El usuario introduce el <i>email</i> y la contraseña. 3. El sistema verifica los credenciales. 4. El sistema crea la sesión y redirige a la página de consultas.
Postcondición	Sesión activa para el usuario.
Excepciones	1. Tiene algún campo vacío $\Rightarrow$ Mostrar error de campo obligatorio. 2. El <i>email</i> o la contraseña no coinciden con ningún usuario registrado $\Rightarrow$ Mostrar error de usuario o contraseña incorrectos. 3. El <i>email</i> no cumple la validación $\Rightarrow$ Mostrar error de <i>email</i> inválido. 4. La contraseña no cumple la política $\Rightarrow$ Mostrar error de contraseña poco segura.
Importancia	Alta.

Tabla B.2: CU-2 Iniciar sesión.

CU-3	Cerrar sesión
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.2
Descripción	Finaliza la sesión del usuario.
Precondición	Que el usuario esté autenticado.
Acciones	1. El usuario pulsa el botón «Cerrar sesión». 2. El sistema invalida la sesión. 3. El sistema redirige a la página de inicio.
Postcondición	Sesión finalizada.
Excepciones	1. Error al invalidar sesión $\Rightarrow$ Mostrar mensaje de error al cerrar sesión.
Importancia	Media.

Tabla B.3: CU-3 Cerrar sesión.

CU-4	Recuperar contraseña
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10 , RF-10.1 , RF-10.6
Descripción	Permite a los usuarios cambiar su contraseña antes de iniciar sesión.
Precondición	Que el usuario esté registrado en el sistema.
Acciones	1. El usuario accede a «Iniciar sesión». 2. El usuario pulsa el enlace «¿No recuerdas la contraseña?». 3. El sistema envía un correo al email del usuario con el enlace a la página de recuperación de contraseña. 4. El usuario accede a la página de recuperar contraseña. 5. El usuario introduce la nueva contraseña y la confirmación de la contraseña. 6. El sistema guarda la nueva contraseña encriptada.
Postcondición	Contraseña cambiada para el usuario.
Excepciones	1. Error al enviar el correo $\Rightarrow$ Mostrar error al enviar el correo. 2. La contraseña no cumple la política $\Rightarrow$ Mostrar error de contraseña poco segura. 3. Las contraseñas no coinciden $\Rightarrow$ Mostrar error de contraseñas distintas.
Importancia	Media.

Tabla B.4: CU-4 Recuperar contraseña.

CU-5	Realizar consulta al <i>RAG</i>
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-6 , RF-7 , RF-8 , RF-9 , RF-11 , RNF-3 , RNF-3.2 , RNF-10 , RNF-11
Descripción	El usuario hace una pregunta, el sistema recupera contexto por similitud, construye el <i>prompt</i> y genera respuesta que incluya las fuentes.
Precondición	Que el usuario esté autenticado y la base de datos vectorial esté disponible.
Acciones	1. El usuario escribe y envía una pregunta. 2. El sistema genera <i>embeddings</i> de la consulta. 3. El sistema busca por similitud en la base de datos vectorial. 4. El sistema construye un <i>prompt</i> con los <i>chunks</i> y las reglas de uso del contexto. 5. El sistema llama al <i>LLM</i> y genera respuestas. 6. El sistema adjunta la trazabilidad de la respuesta, la cual incluye los documentos, metadatos y <i>chunks</i> utilizados. 7. El sistema guarda la consulta en el historial del consultas del usuario.
Postcondición	Respuesta mostrada y consulta registrada.
Excepciones	1. Cuando no hay contexto suficiente $\Rightarrow$ El sistema no responde a la pregunta (para evitar alucinaciones) y muestra un aviso de que falta contexto. 2. <i>Timeout</i> del <i>LLM</i> $\Rightarrow$ Mostrar un mensaje controlado.
Importancia	Alta.

Tabla B.5: CU-5 Realizar consulta al *RAG*.

CU-6	Consultar historial de consultas
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-11.1
Descripción	Permite al usuario ver su lista de preguntas y respuestas anteriores.
Precondición	Que el usuario esté autenticado y existan consultas guardadas.
Acciones	1. El usuario accede al «Historial». 2. El sistema lista las consultas del usuario. 3. El usuario puede abrir una consulta para ver la respuesta completa y la trazabilidad de dicha respuesta.
Postcondición	Historial visualizado.
Excepciones	1. El usuario no ha realizado consultas $\Rightarrow$ Mostrar mensaje de que aun no hay consultas.
Importancia	Alta.

Tabla B.6: **CU-6** Consultar historial de consultas.

CU-7	Borrar consultas del historial
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-11.2
Descripción	Permite al usuario borrar consultas del historial.
Precondición	Que el usuario esté autenticado y existan consultas guardadas.
Acciones	1. El usuario accede al «Historial». 2. El sistema lista las consultas del usuario. 3. El usuario pulsa el botón «Borrar». 4. El sistema elimina la consulta seleccionada de la base de datos. 5. El sistema actualiza la vista del historial.
Postcondición	La consulta seleccionada se elimina del historial del usuario.
Excepciones	1. Error en la base de datos al intentar borrar la consulta $\Rightarrow$ Mostrar mensaje de error controlado. 2. La consulta seleccionada no existe o ya ha sido borrada $\Rightarrow$ Mostrar aviso al usuario.
Importancia	Alta.

Tabla B.7: CU-7 Borrar consultas del historial.

CU-8	Gestión de documentos
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-1 , RF-1.1 , RF-1.2 , RF-1.3 , RF-2 , RF-2.1 , RF-2.2 , RF-2.2.1 , RF-2.3 , RF-2.3.1 , RF-2.3.2 , RF-3 , RF-4 , RF-5 , RF-5.1 , RF-5.2 , RF-5.3 , RF-5.4 , RF-5.5 , RNF-3.1
Descripción	El administrador debe poder gestionar a los documentos de la aplicación.
Precondición	Hay un administrador autenticado.
Acciones	1. El administrador accede a la página de «Iniciar sesión». 2. El administrador introduce su <i>email</i> y contraseña. 3. El sistema le autentifica como administrador. 4. El administrador accede a «Administrar documentos».
Postcondición	Posibilidad de cargar documentos nuevos (de forma manual o por <i>web scraping</i>), indexar, borrar o descargar los documentos ya cargados .
Excepciones	1. Intento de acceso sin ser administrador $\Rightarrow$ Se deniega. 2. Si no hay documentos cargados en la aplicación $\Rightarrow$ Muestra un mensaje.
Importancia	Alta.

Tabla B.8: **CU-8** Gestión de documentos.

CU-9	Cargar documentos de licitaciones
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-1 , RF-10.3 , RF-10.4 , RNF-3 , RNF-3.1
Descripción	El administrador sube documentos para alimentar o ampliar la base de datos vectorial.
Precondición	Que el administrador esté autenticado.
Acciones	1. El administrador pulsa el botón «Cargar». 2. El administrador selecciona uno o varios documentos. 3. El sistema valida los documentos y los almacena. 4. El sistema registra la carga.
Postcondición	Los documentos están disponibles para procesado.
Excepciones	1. Documento corrupto o sin texto legible $\Rightarrow$ Se marca como fallido y se continua con el siguiente.
Importancia	Alta.

Tabla B.9: **CU-9** Cargar documentos de licitaciones.

CU-10	Importar licitaciones automáticamente
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-12 , RF-12.1 , RF-12.2 , RNF-3 , RNF-3.1
Descripción	Permite al administrador importar de manera automática las licitaciones a través de <i>web scraping</i> .
Precondición	Que el administrador esté autenticado y haya un programa de <i>web scraping</i> funcional.
Acciones	1. El administrador accede a «Administrar documentos». 2. El administrador pulsa el botón «Web scraping». 3. El sistema lanza el proceso de <i>web scraping</i>. 4. El sistema guarda los documentos obtenidos y registra sus metadatos. 5. El sistema muestra un resumen con el número de documentos descargados, los duplicados y los fallidos.
Postcondición	Los documentos importados están disponibles para procesado e indexado.
Excepciones	1. Fallo de red $\Rightarrow$ Se registra y muestra al administrador. 2. Documento corrupto o sin texto legible $\Rightarrow$ Se marca como fallido y se continua con el siguiente. 3. Documento duplicado $\Rightarrow$ Se omite y se registra como duplicado.
Importancia	Media.

Tabla B.10: **CU-10** Importar licitaciones automáticamente.

CU-11	Convertir los documentos a <i>Markdown</i>
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-2 , RF-2.1 , RF-2.2 , RF-2.2.1 , RF-2.3 , RF-2.3.1 , RF-2.3.2
Descripción	El sistema prepara automáticamente los documentos para que puedan ser procesados por el sistema.
Precondición	Hay documentos cargados por el administrador.
Acciones	1. El sistema extrae texto descartando páginas y documentos sin texto extraíble. 2. Convierte el texto a <i>Markdown</i> homogéneo. 3. Intenta conservar la estructura básica del documento original. 4. Limpia caracteres problemáticos y normaliza espacios y saltos de línea.
Postcondición	Los documentos convertidos a <i>Markdown</i> listos para el <i>chunking</i> .
Excepciones	1. Documento sin texto $\Rightarrow$ Se marca como no procesable y se continua como los demás.
Importancia	Alta.

Tabla B.11: CU-11 Convertir los documentos a *Markdown*.

CU-12	Indexar documento
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-3 , RF-4 , RF-5 , RF-5.1 , RF-5.2 , RF-5.3
Descripción	Permite al administrador actualizar la base de datos vectorial cuando hay documentos nuevos. El sistema convierte los documentos procesados en <i>chunks</i> , genera los <i>embeddings</i> y los guarda en la base de datos vectorial con metadatos.
Precondición	Existen documentos procesados, una base de datos vectorial y un administrador autenticado.
Acciones	1. El administrador accede a «Administrar documentos». 2. El administrador pulsa el botón «Actualizar Base de Datos Vectorial». 3. El sistema segmenta los archivos en <i>chunks</i>. 4. Aplica solapamiento a dichos <i>chunks</i>. 5. Añade una referencia al documento así como el segmento que contiene. 6. Genera <i>embeddings</i> de cada <i>chunk</i>. 7. Lo almacena en la base de datos vectorial.
Postcondición	La colección vectorial con los nuevos documentos incluidos.
Excepciones	1. Fallo en conseguir los <i>embedding</i> de un <i>chunk</i> $\Rightarrow$ Se omite el <i>chunk</i> y se continúa. 2. Error de conexión con la base de datos vectorial $\Rightarrow$ Se aborta la operación y se avisa al administrador a través de un mensaje.
Importancia	Alta.

Tabla B.12: CU-12 Indexar documento.

CU-13	Listar documentos
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-1.2 , RNF-4
Descripción	Permite al administrador ver el listado de documentos junto con los metadatos relevantes.
Precondición	Hay un administrador autenticado y existe al menos un documento cargado en el sistema.
Acciones	1. El administrador accede a «Administrar documentos». 2. El sistema lista los documentos con sus metadatos (nombre, tamaño, fecha de modificación y <i>chunks</i>).
Postcondición	Documentos visibles para el administrador.
Excepciones	1. No hay documentos $\Rightarrow$ Muestra un mensaje informativo «Aún no hay documentos». 2. Error de base de datos $\Rightarrow$ Muestra un error.
Importancia	Media.

Tabla B.13: CU-13 Listar documentos.

CU-14	Consultar estado del documento
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-1.2 , RNF-4
Descripción	Permite al administrador ver el estado de los documentos cargados en el sistema (cargado, indexado o fallido).
Precondición	Hay un administrador autenticado y existe al menos un documento cargado en el sistema.
Acciones	1. El administrador accede a «Administrar documentos». 2. El sistema lista los documentos con sus metadatos (nombre, tamaño, fecha de modificación y <i>chunks</i>). 3. El sistema muestra el estado de los documentos listados.
Postcondición	Estados de los documentos visibles para el administrador.
Excepciones	1. No hay documentos $\Rightarrow$ Muestra un mensaje informativo «Aún no hay documentos». 2. Error de base de datos $\Rightarrow$ Muestra un error.
Importancia	Media.

Tabla B.14: **CU-14** Consultar estado del documento.

CU-15	Eliminar documento
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-1.3 , RF-5.5 , RNF-5.2
Descripción	Permite al administrador eliminar un documento del sistema, así como sus <i>chunks</i> y <i>embeddings</i> asociados en la base de datos vectorial.
Precondición	Hay un administrador autenticado y existe al menos un documento cargado en el sistema.
Acciones	1. El administrador accede a «Administrar documentos». 2. El sistema lista los documentos con sus metadatos (nombre, tamaño, fecha de modificación y <i>chunks</i>) y estado. 3. El administrador pulsa el botón «Borrar». 4. El sistema pide confirmación. 5. El administrador confirma el borrado. 6. El sistema borra el documento y sus metadatos. Además, si el documento esta indexado borra sus <i>chunks</i> y sus <i>embeddings</i>. 7. El sistema actualiza el listado.
Postcondición	Documento eliminado y sus <i>chunks</i> y <i>embeddings</i> borrados de la base de datos vectorial.
Excepciones	1. El documento no existe $\Rightarrow$ Se muestra un aviso. 2. Error al borra $\Rightarrow$ No se borra y se informa al administrador. 3. Error al borrar en la base de datos vectorial $\Rightarrow$ No se borra el documento y se informa al administrador.
Importancia	Alta.

Tabla B.15: CU-15 Eliminar documento.

CU-16	Descargar documento
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-1 , RF-1.4 , RNF-5.2
Descripción	Permite al administrador descargar un documento del sistema.
Precondición	Hay un administrador autenticado y existe al menos un documento cargado en el sistema.
Acciones	1. El administrador accede a «Administrar documentos». 2. El sistema lista los documentos con sus metadatos (nombre, tamaño, fecha de modificación y <i>chunks</i>) y estado. 3. El administrador pulsa el botón «Descargar». 4. Se descarga el documento.
Postcondición	Documento descargado en el equipo del administrador.
Excepciones	1. El documento no existe $\Rightarrow$ Se muestra un aviso. 2. Error al descargar $\Rightarrow$ Se informa al administrador.
Importancia	Media.

Tabla B.16: CU-16 Descargar documento.

CU-17	Gestión de usuarios
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.3 , RF-10.4
Descripción	El administrador debe poder gestionar a los usuarios de la aplicación y sus permisos.
Precondición	Hay un administrador autenticado.
Acciones	1. El administrador accede a la página de «Iniciar sesión». 2. El administrador introduce su <i>email</i> y contraseña. 3. El sistema le autentifica como administrador. 4. El administrador accede a «Administrar usuarios».
Postcondición	Listado de usuarios para editar.
Excepciones	1. Intento de acceso sin ser administrador $\Rightarrow$ Se deniega. 2. Si no hay usuarios registrados en la aplicación $\Rightarrow$ Mostrar mensaje de que aún no hay usuarios.
Importancia	Media.

Tabla B.17: CU-17 Gestión de usuarios.

CU-18	Crear usuario
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.3 , RF-10.4
Descripción	El administrador crea usuarios desde la web.
Precondición	Hay un administrador autenticado.
Acciones	1. El administrador accede a «Administrar usuarios». 2. El administrador pulsa el botón «Añadir usuario». 3. El administrador introduce el nombre, <i>email</i>, contraseña y si es administrador o no. 4. El sistema valida el formato y que el <i>email</i> no esté duplicado. 5. El sistema almacena el usuario con la contraseña encriptada. 6. El sistema redirige a la página de «Gestión de usuarios».
Postcondición	Usuario creado.
Excepciones	1. Intento de acceso sin ser administrador $\Rightarrow$ Se deniega. 2. Tiene algún campo vacío $\Rightarrow$ Muestra un error con el mensaje «Completa este campo». 3. El <i>email</i> ya existe $\Rightarrow$ Muestra un error con el mensaje «Ya existe un usuario con ese <i>email</i>». 4. El <i>email</i> no cumple la validación $\Rightarrow$ Muestra un error con el mensaje «Invalid <i>email</i> address». 5. La contraseña no cumple la política $\Rightarrow$ Muestra un error con el mensaje «Aumenta la longitud del texto a 6 caracteres como mínimo». 6. El nombre tiene menos de 2 caracteres $\Rightarrow$ Muestra un error con el mensaje «Aumenta la longitud del texto a 2 caracteres o más».
Importancia	Media.

Tabla B.18: CU-18 Crear usuario.

CU-19	Borrar usuario
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.3 , RF-10.4
Descripción	El administrador borra usuarios desde la web.
Precondición	Hay un administrador autenticado y usuarios previamente registrados en la aplicación.
Acciones	1. El administrador accede a «Administrar usuarios». 2. El administrador pulsa el botón «Borrar» del usuario que desee eliminar. 3. El sistema pide confirmación antes de borrar el usuario. 4. El administrador pulsa el botón «Aceptar». 5. El sistema borra al usuario y sus datos de la base de datos.
Postcondición	Usuario borrado.
Excepciones	1. Fallo al conectar con la base de datos $\Rightarrow$ No se borra el usuario y se informa del problema al administrador.
Importancia	Media.

Tabla B.19: CU-19 Borrar usuario.

CU-20	Modificar rol del usuario
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.3 , RF-10.4
Descripción	El administrador puede cambiar el rol de los usuarios desde la web.
Precondición	Hay un administrador autenticado y usuarios previamente registrados en la aplicación.
Acciones	1. El administrador accede a «Administrar usuarios». 2. El administrador pulsa el botón «Hacer admin»/«Quitar admin» del usuario que desee cambiar de rol. 3. El sistema cambia el rol del usuario.
Postcondición	Usuario con el rol cambiado.
Excepciones	1. Fallo al conectar con la base de datos $\Rightarrow$ No se cambia el rol del usuario y se informa del problema al administrador.
Importancia	Baja.

Tabla B.20: **CU-20** Modificar rol del usuario.

CU-21	Editar usuario
Versión	1.0
Autor	Lydia Blanco Ruiz
Requisitos asociados	RF-10.5 , RNF-5.1 , RNF-5.2
Descripción	Permite que un usuario edite sus datos y contraseña.
Precondición	Hay un usuario autenticado.
Acciones	1. El usuario accede a «Editar usuario». 2. Modifica los campos que desee (nombre, <i>email</i> o contraseña). 3. El sistema valida los formatos y reglas. 4. El sistema guarda los cambios. Si hay cambio de contraseña la almacena encriptada.
Postcondición	Datos del usuario actualizados.
Excepciones	1. Se intenta cambiar el <i>email</i> por otro que ya existe en el sistema $\Rightarrow$ Muestra un error con el mensaje «Ya existe un usuario con ese <i>email</i>». 2. El <i>email</i> no cumple la validación $\Rightarrow$ Muestra un error con el mensaje «Invalid <i>email</i> address». 3. La contraseña no cumple la política $\Rightarrow$ Muestra un error con el mensaje «Aumenta la longitud del texto a 6 caracteres como mínimo». 4. El nombre tiene menos de 2 caracteres $\Rightarrow$ Muestra un error con el mensaje «Aumenta la longitud del texto a 2 caracteres o más».
Importancia	Baja.

Tabla B.21: CU-21 Editar usuario.

Apéndice C

Especificación de diseño

C.1. Introducción

C.2. Diseño de datos

Para llevar a cabo la aplicación se han definido las siguientes entidades:

- **Usuario:** esta entidad representa a la persona que usa la aplicación. Distingue entre usuario normal y administrador, al cual le permite realizar la gestión de documentos y usuarios. Esta entidad maneja un identificador (id) que es la clave primaria, un nombre, un email que debe ser único, una contraseña que se almacena encriptada, el último inicio de sesión y el rol.
- **Consulta:** esta entidad guarda las preguntas que realizan los usuarios, así como las respuestas que da el *LLM* alimentado por el *RAG*. Es la base para el historial de consultas donde se van a listar y borrar. Esta entidad maneja un identificador (id) que es la clave primaria, el identificador del usuario que realiza la consulta, la pregunta del usuario, la respuesta, los fragmentos utilizados, el tiempo de respuesta, y la fecha en la que se preguntó al modelo.
- **Documento:** esta entidad representa un PDF cargado en la aplicación. Maneja un identificador (id) como clave primaria, el nombre del fichero, el tamaño, la fecha de modificación, el número de *chunks* en la base de datos vectorial, el *hash* del documento y el estado del documento (cargado, procesado, indexado, fallido).
- **Chunk:** esta entidad representa cada trozo de texto en el que se dividen los documentos para poder generar los *embeddings*. Maneja el texto

que forma al propio *chunk*, el *embedding* y los metadatos del *chunk* (nombre del archivo, título y posición dentro del documento).

- *Embedding*: esta entidad se corresponde con la representación vectorial utilizada para la base de datos vectorial. Va a permitir recuperar *chunks* por similitud. La entidad maneja un vector asociado al *chunk*.
- *ConsultaChunk*: esta entidad modela la relación entre las consultas y los *chunks* permitiendo que una consulta tenga varios *chunk* y que un *chunk* pueda servir para varias consultas. La entidad maneja el identificador de la consulta, el identificador del *chunk*, la similitud con la consulta del usuario y el *ranking*. El *ranking* hace referencia a la relevancia que tiene un *chunk* entre los recuperados para aumentar el *prompt* del *LLM*. La posición del *chunk* en el *ranking* se determina ordenandolos descendientemente según su similitud.

Las relaciones entre las entidades son:

- Un usuario puede hacer cero o varias consultas.
- Cada consulta pertenece a un usuario.
- Un documento tiene cero (si está cargado pero no indexado) o varios *chunks*.
- Cada *chunk* pertenece a un documento.
- Un *chunk* tiene un *embedding*.
- Cada *embedding* pertenece a un *chunk*.
- Una consulta usa uno o varios *chunk*.
- Un *chunk* puede ser usado por cero o varias consultas.

El diagrama entidad relación se muestra en esta imagen [C.1](#)

El diagrama relacional se muestra en esta imagen [C.2](#)

C.3. Diseño arquitectónico

El objetivo del diseño arquitectónico es garantizar la modularidad, la escalabilidad, la mantenibilidad, la portabilidad y la reproducibilidad del sistema desarrollado. Es decir, se busca tener una separación clara de responsabilidades entre la interfaz, la lógica, la persistencia y los servicios de Inteligencia Artificial con una organización del código en componentes cohesivos (*Blueprints*, servicios y modelos), pudiendo replicarse los servicios de manera sencilla. Además, sustituir los componentes debe tener un impacto mínimo en el resto del código.




Figura C.1: Diagrama Entidad/Relación.

Este sistema se basa en una arquitectura cliente-servidor multicapa, combinada con una arquitectura *RAG* (*Retrieval-Augmented Generation*), en la capa de aplicación, estructurada en dos *pipelines* diferenciados, el de indexación y el de generación. El despliegue se lleva a cabo utilizando contenedores *Docker* para almacenar el código junto con sus dependencias.

Arquitectura general del sistema

El sistema sigue una arquitectura distribuida basada en servicios (*service-oriented* [3]), donde cada componente tiene una responsabilidad claramente definida. La aplicación se compone de los siguientes elementos principales:

- Cliente *web*: se corresponde con el navegador del usuario.
- Servidor de *proxy* inverso *Nginx*: el cual se encarga del protocolo de seguridad a través del certificado SSL/TLS, las redirecciones HTTP a HTTPS y el encaminamiento hacia la aplicación .




Figura C.2: Diagrama relacional.

- Capa de aplicación: aplicación *Flask* desplegada tras un servidor WSGI *Gunicorn*.
- Persistencia relacional: se incluye *PostgreSQL* como base de datos relacional para asegurar la persistencia de los datos de las transacciones, como son los usuarios, las consultas, los documentos o los estados.
- Persistencia vectorial: se utiliza *Qdrant* como base de datos vectorial para realizar la búsqueda semántica sobre los *embeddings*.
- Servicio de modelos *LLM*: se utiliza *Ollama* para servir el modelo *LLM* de manera local exponiendo una API HTTP de generación.
- Contenedor de pruebas: se utiliza este contenedor para la ejecución de las pruebas del sistema, así como, de la cobertura de dichas pruebas.

La comunicación entre componentes (ver imagen C.3) se realiza principalmente dentro de la red interna de **Docker-compose**, donde los servicios se resuelven entre sí mediante el nombre de servicio, es decir, el DNS interno, y se conectan a través de los puertos expuestos internamente. El acceso desde el exterior se gestiona usando *Nginx*, que es el único componente que publica puertos hacia internet (el puerto 80 para el protocolo HTTP y el 443 para el HTTPS). *Nginx* actúa como *proxy* inverso y punto de terminación TLS. Recibe las peticiones que hacen los usuarios a la *web* **pythia.es** y las reenvía por HTTP interno al servicio *web* en **web:5000** que se corresponde con la aplicación *Flask* servida con *Gunicorn*. Desde la aplicación, las comunicaciones con los servicios de datos se realizan dentro del entorno *Docker*. La conexión con la base de datos relacional *PostgreSQL* se gestiona con una conexión TCP a **db:5432**. La conexión con la base de datos vectorial *Qdrant*, para la recuperación semántica, se realiza mediante conexión HTTP por el puerto **qdrant:6333**. Para generar las respuestas se invoca el servicio *Ollama* por HTTP en **ollama:11434**. *Ollama* puede ser accesible desde fuera del *host* gracias al mapeo de puertos **11435:11434**. Por último, el contenedor *ollama-init* se comunica con *Ollama* de forma interna durante el arranque para descargar el modelo y dejarlo disponible antes de su uso. En el diagrama C.4 se puede observar como atiende el sistema las peticiones de los usuarios.

Arquitectura lógica

Desde el punto de vista lógico el sistema se estructura siguiendo una arquitectura multicapa, organizada en tres niveles claramente diferenciados. Estos niveles se corresponden con la capa de presentación, la capa de aplicación y la capa de persistencia y servicios externos (ver arquitectura en la imagen C.5).




Figura C.3: Diagrama de la comunicación entre los principales componentes del sistema.




Figura C.4: Diagrama de la gestión de peticiones del sistema.




Figura C.5: Diagrama de la arquitectura lógica del sistema.

- **Capa de presentación:** es la interfaz de usuario (IU) del sistema y es accesible a través del navegador web. Se sigue un enfoque SSR (*Server-Side Rendering*), en el que las páginas HTML se generan en el servidor mediante plantillas (usando las plantillas `Jinja2` en `Flask`) y se envían al navegador ya renderizadas. Esto reduce la complejidad en el cliente, simplifica el control de acceso y la validación en el servidor. Mejora la trazabilidad y el registro de las interacciones y simplifica la integración del *pipeline RAG*.
- **Capa de aplicación:** se implementa en el contenedor *web*, que es donde se ejecuta la aplicación `Flask` servida por `Gunicorn`. Esta capa es responsable de coordinar la lógica funcional del sistema y actúa como núcleo del procesamiento. Esta compuesta por los controladores (rutas) organizados en *Blueprints* encargados de gestionar las peticiones HTTP, la lógica de negocio (gestión de usuarios, documentos, consultas, etc) y el *pipeline RAG*.
- **Capa de persistencia y servicios externos:** en esta capa se agrupan los sistemas encargados del almacenamiento y procesamiento de los datos. Se incluyen las bases de datos, tanto la relacional `PostgreSQL` como la vectorial `Qdrant`. También, se incluye `Ollama` como proveedor del modelo *LLM*. Todos estos servicios se ejecutan como contenedores independientes dentro de la red interna de `Docker`, garantizando aislamiento, modularidad y facilidad de despliegue.

Arquitectura de la aplicación *web*

La aplicación *web* sigue una arquitectura MVC (*Model-View-Controller*). Esta arquitectura es típica de las aplicaciones *Flask server-side-rendered* (SSR) [2]. La técnica SSR consiste en generar el código de las páginas en el lado del servidor y entregar al cliente el código **HTML** completamente montado con toda la información que se debe mostrar.

El modelo vista controlador (MVC) [1] es un patrón arquitectónico de software que separa el código en tres capas independientes. La capa modelo donde se incluye la lógica y los datos, la capa vista donde se implementa la interfaz de usuario (*frontend*) y la capa controlador que actúa de intermediario entre las acciones del usuario en las vistas y la lógica de la aplicación (rutas). En esta aplicación se implementa adaptado al ecosistema *Flask* de la siguiente forma:

- La vista: está compuesta por las plantillas **HTML** renderizadas mediante el motor de plantillas **Jinja2**, responsables de presentar la interfaz y capturar las interacciones del usuario. Además, incorpora los recursos estáticos (**css** y **JavaScript**). Aunque, la aplicación incorpora *JavaScript* para mejorar la experiencia de usuario, la generación principal del contenido es *server-side*, por lo que la arquitectura sigue siendo fundamentalmente SSR.
- El controlador: se implementa mediante rutas *Flask* organizadas en *Blueprints*. El uso de *Blueprints* permite mantener alta cohesión dentro de cada módulo y bajo acoplamiento entre funcionalidades. Se encarga de gestionar las peticiones HTTP, realizar validaciones básicas (como las de los formularios), así como controlar de acceso por rol. También, tiene la responsabilidad de invocar los servicios donde se encuentra la lógica, coordinar el *pipeline RAG* y generar las respuestas HTTP (renderizando la vista adecuada).
- El modelo: esta compuesto por las entidades de datos persistentes (Usuario, Consulta, Documento, *Chunk*, *Embedding* y la relación *ConsultaChunk*) y por la lógica de negocio asociada (gestión de usuarios, administración documental, *pipelines* de consulta e indexación *RAG*, control de estados de procesos largos, etc). Se usa una base de datos relacional (*PostgreSQL*) para asegurar la persistencia de los datos de la aplicación y una base de datos vectorial (*Qdrant*) para la recuperación semántica. Esta capa permite desacoplar la lógica de negocio de la base de datos subyacente.

Con estas capas se mantiene el desacoplamiento de la aplicación *web*, haciendo que los controladores organicen el flujo para que la interfaz de usuario no implemente reglas de negocio y sea el modelo el que encapsule los datos y los procesos del dominio.

Arquitectura del sistema *RAG*

El sistema *RAG* se integra dentro de la capa de aplicación y se estructura en dos *pipelines*, el de indexación y el de generación:

El *pipeline* de indexación se ejecuta cuando se cargan los documentos en la aplicación, ya bien sea de manera manual o mediante *web scraping*. Por cada documento se va a llevar a cabo una conversión a **Markdown**. De estos documentos se extrae, limpia y normaliza su texto, posteriormente se segmenta en *chunks* con solapamiento y se generan sus *embeddings*. Los cuales se van a almacenar en *Qdrant*. Este proceso se ejecuta de forma asíncrona para evitar bloquear la interfaz *web* y envía un correo electrónico al usuario cuando finaliza.

El *pipeline* de generación se activa cuando el usuario hace una consulta, generando los *embeddings* de la consulta. Una vez generados recupera los *chunks* más relevantes de *Qdrant* por la similitud de sus *embeddings* y los usa para construir el *prompt* aumentado. Envía el *prompt* generado al modelo *LLM* y muestra su respuesta al usuario. Finalmente registra la consulta en la base de datos relacional. Este *pipeline* combina recuperación semántica y generación de texto, asegurando trazabilidad al devolver los metadatos de los documentos fuente.

Arquitectura de despliegue e infraestructura

El sistema se despliega mediante contenedores *Docker*. Los servicios se definen en el archivo **Docker Compose**. Se definen seis contenedores independientes que se corresponden con el entorno para la base de datos relacional *PostgreSQL* llamado **db**, el de la base de datos vectorial *Qdrant* llamado **qdrant**, el de el servicio *LLM* llamado **Ollama**, el de la aplicación *Flask* levantada usando *Gunicorn* llamado **web**, el del *proxy* inverso **nginx** y el contenedor de ejecución de pruebas llamado **test**.

Gracias a esta separación se garantiza la seguridad ya que no se expone directamente la aplicación *Flask*. Este despliegue también, aumenta la escalabilidad, la reproducibilidad y la portabilidad al tener la posibilidad de replicar los servicios en un entorno aislado que no depende del sistema anfitrión.




Figura C.6: Prototipo de la página de inicio.

C.4. Diseño procedimental

C.5. Diseño de interfaces

El diseño de las interfaces se ha desarrollado de manera incremental. Inicialmente se hicieron bocetos genéricos para plasmar las principales funcionalidades de la aplicación. Posteriormente se fue iterando sobre esos diseños hasta llegar a las interfaces finales de la *web*.

Los prototipos iniciales que se crearon se ilustran en las figuras [C.6](#), [C.7](#), [C.8](#), [C.9](#), [C.10](#), [C.11](#), [C.12](#), [C.13](#), [C.14](#), [C.15](#) y [C.16](#).

Aunque estos prototipos se asemejan mucho a las interfaces finales, se han realizado diversos cambios. Por ejemplo, se ha cambiado la cabecera para aportar más información como el nombre del usuario que inicia sesión, su rol (usuario normal o administrador) y su último inicio de sesión (ver imagen de la cabecera final [C.17](#)). Además, se ha añadido a la tabla del historial de consultas y a la de documentos cargados información relevante que no se había valorado inicialmente. En la tabla del historial de consultas se han añadido diversos campos para aportar toda la información relevante sobre la consulta. Añadiendo el documento al que pertenece el *chunk* principal y la fecha en la que el usuario hizo la consulta. Para el administrador, también,

Prototipo de la página de inicio de sesión. La interfaz se muestra dentro de un navegador web con una barra de direcciones y botones de navegación. El formulario centralizado tiene el título "Inicio De Sesión". Contiene dos campos de entrada: "Email" y "Contraseña", cada uno con un ícono de ojo para alternar la visibilidad. Debajo de los campos hay dos botones: "Iniciar" y "Registrarse".

Figura C.7: Prototipo de la página de inicio de sesión.

Prototipo de la página de registro. La interfaz se muestra dentro de un navegador web con una barra de direcciones y botones de navegación. El formulario centralizado tiene el título "Registro". Contiene cuatro campos de entrada: "Nombre", "Email", "Contraseña" y "Repite la contraseña". Debajo de los campos hay dos botones: "Registrarse" y "Iniciar Sesión".

Figura C.8: Prototipo de la página de registro.




Figura C.9: Prototipo de la página principal.




Figura C.10: Prototipo de la página del historial.




Figura C.11: Prototipo de los detalles del historial.


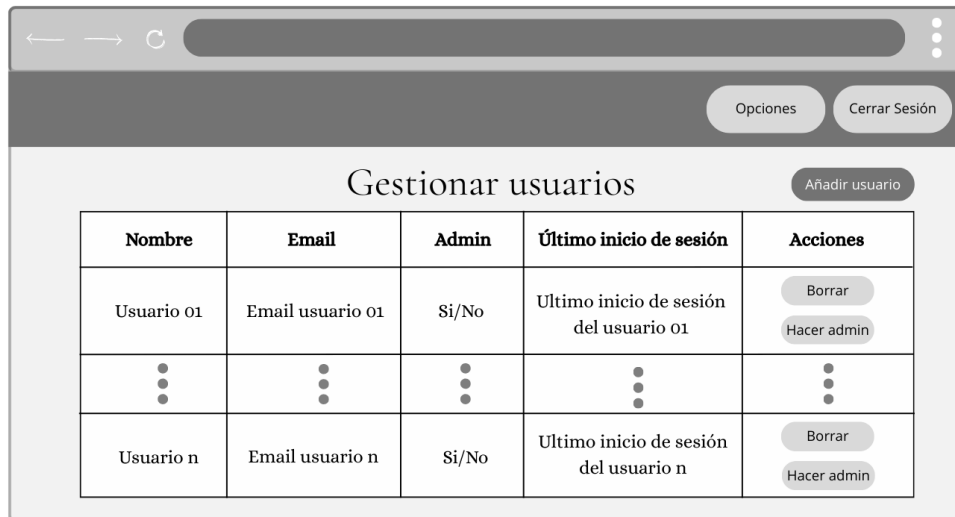


Figura C.12: Prototipo de la página de consulta.



Prototipo de la página de gestión de usuarios. La interfaz incluye una barra de navegación superior con botones "Opciones" y "Cerrar Sesión". El título principal es "Gestionar usuarios", acompañado de un botón "Añadir usuario". El contenido principal es una tabla con las siguientes columnas: Nombre, Email, Admin, Último inicio de sesión y Acciones. La tabla muestra dos usuarios: "Usuario 01" y "Usuario n".

Nombre	Email	Admin	Último inicio de sesión	Acciones
Usuario 01	Email usuario 01	Si/No	Ultimo inicio de sesión del usuario 01	<button>Borrar</button> <button>Hacer admin</button>
⋮	⋮	⋮	⋮	⋮
Usuario n	Email usuario n	Si/No	Ultimo inicio de sesión del usuario n	<button>Borrar</button> <button>Hacer admin</button>

Figura C.13: Prototipo de la página de gestión de usuarios.



Prototipo de la página de añadir usuarios. La interfaz muestra un formulario con los campos: Nombre, Email, Contraseña y un checkbox "¿Es administrador?". Un botón "Añadir usuario" está ubicado al final del formulario.

Añadir usuario

Nombre

Email

Contraseña

☐ ¿Es administrador?

Añadir usuario

Figura C.14: Prototipo de la página de añadir usuarios.



Figura C.15: Prototipo de la página de edición del usuario.




Figura C.16: Prototipo de la página de gestión de documentos.




Figura C.17: Diseño de interfaz – Cabecera.

se ha añadido una columna en la que se indica el nombre del usuario que hizo la consulta. Además, para mejorar la legibilidad de la tabla se ha decidido ubicar la respuesta debajo de la fila en un desplegable (ver imagen del historial de consulta definitivo C.18). Por su parte, en la tabla donde se muestran los documentos cargados del sistema se han añadido dos columnas, una que indica el tamaño del documento y otra que indica el estado de ese documento en el sistema (cargado, indexado o fallido) (ver imagen del diseño final de la tabla documentos C.19). Otro aspecto relevante es que en la página para realizar la consulta se ha añadido un desplegable para ver los *chunks* utilizados (ver imagen de la página de consultas definitiva C.20).

En estos diagramas C.21 y C.22 se muestra como sería la navegabilidad de los usuario por la aplicación dependiendo del rol que tienen (administrador o usuario normal).

Administrador:

Usuario	Fecha	Pregunta	Documento	Tiempo	Acciones
Nombre del usuario que hizo la consulta n	Fecha en la que el usuario hizo la consulta n	Pregunta del usuario	Nombre del documento al que pertenece el <i>chunk</i> principal	Tiempo que tardó el modelo en responder	Borrar Detalles
▶ Ver respuesta					
Nombre del usuario que hizo la consulta 01	Fecha en la que el usuario hizo la consulta 01	Pregunta del usuario	Nombre del documento al que pertenece el <i>chunk</i> principal	Tiempo que tardó el modelo en responder	Borrar Detalles
▶ Ver respuesta					

Usuario normal:

Fecha	Pregunta	Documento	Tiempo	Acciones
Fecha en la que el usuario hizo la consulta n	Pregunta del usuario	Nombre del documento al que pertenece el <i>chunk</i> principal	Tiempo que tardó el modelo en responder	Borrar Detalles
▶ Ver respuesta				
Fecha en la que el usuario hizo la consulta 01	Pregunta del usuario	Nombre del documento al que pertenece el <i>chunk</i> principal	Tiempo que tardó el modelo en responder	Borrar Detalles
▶ Ver respuesta				

Figura C.18: Diseño de interfaz – Historial de consultas.

Archivo	Tamaño	Modificado	Chunk	Estado	Acciones
Nombre del documento 01	Tamaño del documento 01	Fecha de modificación en el sistema	Número de <i>chunks</i> indexados en el sistema	cargado/indexado/ fallido	Borrar
Resto de filas con los nombres	Resto de filas con el tamaño	Resto de filas con las fechas de modificación	Resto de filas con los <i>chunks de los documentos</i>	Resto de fila con el estado (cargado/indexado/ fallido)	Borrar
Nombre del documento n	Tamaño del documento n	Fecha de modificación en el sistema	Número de chunks indexados en el sistema	cargado/indexado/ fallido	Borrar

Figura C.19: Diseño de interfaz – Tabla de documentos cargados.

Preguntar al modelo (RAG)

Escribe tu pregunta y mira la respuesta y el fragmento usado.

Pregunta

Escribe tu pregunta....

Preguntar

Respuesta

► Fragmento usado

Figura C.20: Diseño de interfaz – Interfaz de consulta al modelo.




Figura C.21: Diagrama de navegabilidad por la aplicación para el administrador.




Figura C.22: Diagrama de navegabilidad por la aplicación para el usuario normal.

Apéndice D

Documentación técnica de programación

- D.1. Introducción
- D.2. Estructura de directorios
- D.3. Manual del programador
- D.4. Compilación, instalación y ejecución del proyecto
- D.5. Pruebas del sistema

Apéndice E

Documentación de usuario

- E.1. Introducción
- E.2. Requisitos de usuarios
- E.3. Instalación
- E.4. Manual del usuario

Apéndice F

Anexo de sostenibilización curricular

F.1. Introducción

Este anexo incluirá una reflexión personal del alumnado sobre los aspectos de la sostenibilidad que se abordan en el trabajo. Se pueden incluir tantas subsecciones como sean necesarias con la intención de explicar las competencias de sostenibilidad adquiridas durante el alumnado y aplicadas al Trabajo de Fin de Grado.

Más información en el documento de la CRUE https://www.crue.org/wp-content/uploads/2020/02/Directrices_Sostenibilidad_Crue2012.pdf.

Este anexo tendrá una extensión comprendida entre 600 y 800 palabras.

Bibliografía

- [1] Miguel Angel Alvarez. Qué es mvc, 2023. [Online; descargado 1-Marzo-2026].
- [2] Fernán García de Zúñiga. ¿qué es server side rendering (ssr) y cuáles son sus ventajas?, 2025. [Online; descargado 1-Marzo-2026].
- [3] Red Hat. Soa: ¿qué es la arquitectura orientada a los servicios?, 2026. [Online; descargado 1-Marzo-2026].
- [4] Abhinav Kimothi. *A Simple Guide to Retrieval Augmented Generation*. Manning Publications, July 2025. [Consultado 8-Septiembre-2025 a 26-Septiembre-2025].
- [5] Kenneth C. Laudon and Jane P. Laudon. *Management Information Systems*. Pearson, 2012. [Consultado 15-Enero-2026 a 6-Febrero-2026].