



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



**TFG del Grado en Ingeniería
Informática**

Titulo TFG



Presentado por Lydia Blanco Ruiz
en Universidad de Burgos — 28 de septiembre
de 2025

Tutor: Nombre Tutor
y Nombre Co-tutor



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



D. Nombre Tutor y Nombre Co-tutor, profesores del departamento de Ingeniería Informática, área de nombre área.

Expone:

Que el alumno D. Lydia Blanco Ruiz, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado Título TFG.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 28 de septiembre de 2025

Vº. Bº. del Tutor:

Vº. Bº. del co-tutor:

D. Nombre Tutor

D. Nombre Co-tutor

Resumen

En este primer apartado se hace una **breve** presentación del tema que se aborda en el proyecto.

Descriptores

Palabras separadas por comas que identifiquen el contenido del proyecto Ej: servidor web, buscador de vuelos, android ...

Abstract

A **brief** presentation of the topic addressed in the project.

Keywords

keywords separated by commas.

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vi
1. Introducción	1
2. Objetivos del proyecto	3
2.1. Objetivos específicos	3
2.2. Objetivos personales	4
3. Conceptos teóricos	5
3.1. LLM	5
3.2. RAG	6
3.3. Conexión del LLM con el RAG	7
3.4. Diseño del RAG	8
3.5. Evaluación de calidad del RAG	11
3.6. <i>Web Scraping</i>	12
4. Técnicas y herramientas	13
4.1. Metodologías	13
4.2. Repositorio	13
4.3. Gestión de tareas	14
4.4. L ^A T _E X	14
4.5. <i>Web Scraping</i>	14
5. Aspectos relevantes del desarrollo del proyecto	15

6. Trabajos relacionados	17
7. Conclusiones y Líneas de trabajo futuras	19
Bibliografía	21

Índice de figuras

Índice de tablas

1. Introducción

Descripción del contenido del trabajo y del estructura de la memoria y del resto de materiales entregados.

2. Objetivos del proyecto

El objetivo principal del proyecto es diseñar e implementar un sistema de *Retrieval-Augmented Generation* (RAG) que permita enriquecer las respuestas de un modelo de lenguaje mediante la recuperación y utilización de información contextual proveniente de una colección documental.

2.1. Objetivos específicos

Los objetivos identificados en el presente trabajo fin de grado son los siguientes:

- Preprocesar la colección documental.
 - Segmentar los documentos en fragmentos.
 - Normalizar y limpiar el texto.
 - Generar *embeddings* para representar semánticamente los fragmentos.
- Implementar y gestionar un índice vectorial.
 - Almacenar los *embeddings* en una base de datos vectorial.
 - Optimizar consultas de similitud para recuperar contexto relevante.
- Desarrollar la capa de interacción con el usuario
 - Transformar la consulta en su representación vectorial.
 - Recuperar los fragmentos más relevantes del índice.
 - Integrar los fragmentos en el prompt para enriquecer la respuesta del LLM.

2.2. Objetivos personales

- Adquirir conocimientos sobre los sistemas RAG, comprendiendo sus fundamentos, componentes y aplicaciones en el ámbito de la inteligencia artificial.
- Profundizar en el estudio de los modelos de lenguaje de gran tamaño (LLM).
- Desarrollar habilidades prácticas en la implementación de sistemas basados en RAG y LLM.
- Aprender a aplicar los sistemas RAG y los LLM en la resolución de problemas reales.
- Aplicar los conocimientos adquiridos durante la carrera.

3. Conceptos teóricos

En este apartado se considera importante definir qué es un RAG y cuáles son sus aportaciones más significativas a los LLM que ya existen. Además se considera importante contextualizar su origen, y para ello se va a comenzar explicando que son los LLM y sus principales limitaciones.

3.1. LLM

Los *Large Language Model* (LLM), que se traduce como los grandes modelos del lenguaje, son modelos de aprendizaje automático que han sido entrenados con grandes conjuntos de datos generados por humanos. Estos datos se usan para encontrar patrones estadísticos y replicar nuestras habilidades lingüísticas. Por lo cual, se puede decir que en esencia son modelos de predicción del siguiente *token* o lo que es lo mismo de la siguiente palabra [2].

Algunos ejemplos de LLM son ChatGPT¹, Claude² o Llama³.

Las principales características de los LLM son las siguientes:

- Naturaleza de predicción del próximo token: como se ha mencionado anteriormente los LLM seleccionan la palabra más probable de una distribución. La elección de esta palabra se basa en los patrones estadísticos que ha aprendido con los datos del entrenamiento.

¹OpenAI. ChatGPT. Disponible en: <https://chat.openai.com>.

²Anthropic. Claude. Disponible en: <https://claude.ai>.

³Meta AI. Llama. Disponible en: <https://ai.meta.com/llama/>

- Memoria paramétrica: es el conocimiento interno del LLM. Consiste en la información con la que ha sido entrenado y se basa únicamente en sus parámetros. Por lo cual es una memoria limitada y estática.

Las principales limitaciones de los LLM son las siguientes:

- Desactualizado: los eventos posteriores al entrenamiento del LLM, es decir, la fecha de corte del conocimiento, no estarán disponibles para el modelo lo que puede hacer que la respuesta este desactualizada. Además, el entrenamiento de un LLM es muy costoso y lleva mucho tiempo, por lo cual no se reentrenan con mucha frecuencia.
- Alucinaciones: a veces los LLM dan respuestas incorrectas con gran confianza de manera que parece que la información que te está dando es verdadera. Esto se debe a su naturaleza de predicción del próximo *token*.
- Limitación de conocimiento: los LLM se entrenan con datos públicos, lo que limita su conocimiento, ya que no tienen conocimientos de información que no sea pública, como, por ejemplo, documentos internos de una empresa, información de los clientes o de los productos.

Para solventar las limitaciones que se han comentado la solución es darle al LLM el contexto que le falta. El contexto del LLM es la información no paramétrica que se le proporciona en la consulta o *prompt* para que el modelo genere una respuesta más precisa, actual y fundamentada. Para proporcionarle este contexto se puede expandir la memoria del LLM mediante generación aumentada, es decir, incorporando un RAG.

3.2. RAG

Retrieval Augmented Generation (RAG), o en español, generación aumentada por recuperación, es una técnica que consiste en recuperar la información que sea relevante de una fuente externa. Con dicha información aumenta la entrada al LLM, lo que permite que el LLM genere una respuesta mucho más precisa, contextual y confiable. Para realizar esto, el RAG usa tres pasos: recuperar, aumentar y generar.

EL RAG combina dos tipos de memoria:

- La memoria paramétrica: es la que típicamente tienen los LLM, que como se ha visto es limitada y estática.

- La memoria no paramétrica: es información externa al LLM que se le puede proporcionar. Es un conocimiento externo y dinámico que se puede extender tanto como se desee y que puede contener documentos propietarios.

Por lo cual conociendo esto, se puede decir que la generación aumentada por recuperación (RAG) es una metodología que busca ampliar la memoria paramétrica de un LLM incorporando una memoria no paramétrica explícita. A través de un recuperador, se obtiene información relevante de esta memoria externa, la cual se añade al *prompt* y luego se envía al LLM. De esta forma, el modelo puede producir respuestas más contextuales, confiables y precisas [2].

Los objetivos de RAG son:

- Hacer que los LLM respondan con información actualizada.
- Hacer que los LLM respondan información precisa, contextual y confiable.
- Hacer que los LLM conozcan información propietaria.

Las principales ventajas de RAG son:

- Conocimiento del contexto profundo: esto se debe a que la información adicional ayuda al LLM a generar respuestas contextualmente apropiadas, ya que, las respuestas se basan en datos específicos. Esto aumenta la confianza del usuario.
- Citar fuentes: como la información se extrae de fuentes conocidas las puede citar en su respuesta. Esto dispara la fiabilidad y permite a los usuarios comprobar la información obtenida.
- Reduce las alucinaciones: el sistema esta anclado a los hechos, por lo que se reducen las respuestas inexactas o falsas.

3.3. Conexión del LLM con el RAG

El primer paso es el de recopilar los documentos externos y convertirlos a vectores numéricos (*embeddings*) y almacenarlos. Cuando llega una consulta (*prompt*), en lugar de buscar coincidencias por palabras, se busca en ese espacio vectorial los fragmentos que son semánticamente más parecidos, a esto se le conoce como búsqueda por significado. Esos fragmentos se incorporan como contexto al LLM, de modo que el RAG combina la capacidad de razonamiento del modelo con una recuperación de información altamente precisa.

3.4. Diseño del RAG

Un sistema RAG se construye en dos *pipelines* complementarios, el de indexación (*offline*/asíncrono), y el de generación (*online*/ tiempo real). El primero crea y mantiene la memoria no paramétrica o base de conocimiento. El segundo gestiona la interacción con el usuario, realizando la recuperación, el aumento del *prompt* y la generación de la respuesta. Esta separación es estructural en el diseño de RAG y permite optimizar la precisión y la latencia del sistema [2].

Pipeline de Indexación (*offline*)

Su objetivo es consolidar y preparar el conocimiento para que el *pipeline* de generación pueda consultarlo eficientemente. Consta de cinco pasos:

1. Conectarse a las fuentes externas.
2. Extraer y *parsear* los documentos.
3. Dividir textos largos en fragmentos más pequeños denominados *chunks*.
4. Convierte los *chunks* a un formato adecuado
5. Almacena en una base de datos vectorial los *embeddings*

Además de crearlo, este *pipeline* mantiene y actualiza el conocimiento base, por lo que debe ejecutarse de forma periódica [2].

Los componentes clave del *pipeline* de indexación son:

- Carga de datos (*data loading*): consiste en conectarse a las fuentes, por ejemplo, sistemas de archivos, data lakers, CMS o APIs, para la extracción del texto en bruto y el parsing de este en formatos heterogéneos, como pueden ser PDF, DOCX, JSON o HTML. Luego se le añaden metadatos y finalmente se hace limpieza quitando código, etiquetas raras y enmascarando datos confidenciales.
- División de texto (*chunking*): segmentación en unidades manejables, los *chunks*, para mejorar la recuperación y el alineamiento con las capacidades de contexto LLM. Ayuda a respetar la ventana de contexto, mitiga el problema de pérdida en el medio y facilita la búsqueda eficiente. Para dividir el texto puede usar diversos métodos:
 - Tamaño fijo: divide el texto en longitudes uniformes, como un número de caracteres o *tokens*.

- Especializados: divide el texto basándose en su estructura como encabezados o párrafos.
- Semántico: divide el texto basándose en su similitud de significado usando *embeddings*, aunque este método aun es experimental.

La estrategia elegida va a depender del tipo de contenido, la longitud y complejidad de la consulta, el caso de uso y el modelo de *embeddings*.

- Conversión a vectores (*embeddings*): transforma el texto a representaciones numéricas de n dimensiones. Para conocer si los *chunks* se parecen a la consulta, el sistema mide la distancia entre sus vectores, ya que la proximidad refleja similitud semántica. Hay diversas técnicas para medir la distancia entre los vectores, una de las más utilizadas es la similitud coseno que consiste en que si el ángulo entre dos vectores es muy pequeño su similitud es casi uno, pero hay otras como la distancia euclidiana. Hay modelos preentrenados abiertos y propietarios, la elección dependerá de su uso, rendimiento, recuperación y coste.
- Almacenamiento: los *embeddings* se almacenan en bases de datos vectoriales diseñadas para vectores de altas dimensiones. Estas bases de datos vectoriales permiten la búsqueda eficiente sobre *embeddings* y metadatos. Hay diversas opciones:
 - Índices vectoriales: son bibliotecas mínimas centradas en indexación y búsqueda de alta dimensión, no gestionan datos ni ofrecen consultas ricas o interfaces de bases de datos. Ejemplos: FAISS, NMSLIB, ANNOY, ScaNN. Son útiles cuando se desea máximo control y rendimiento sin sobrecarga de base de datos.
 - Bases de datos vectoriales especializadas: añaden a lo anterior gestión de datos, seguridad, escalado, extensibilidad y metadatos, manteniendo búsqueda/similitud vectorial eficiente. Ejemplos: Pinecone, ChromaDB, Milvus, Qdrant.
 - Plataformas de búsqueda: son motores de texto tradicional (Solr, Elasticsearch, OpenSearch, Lucene) que han incorporado similitud vectorial a sus capacidades.
 - Motores SQL/NoSQL con capacidad vectorial: son bases de datos ya existentes que añaden tipos y operadores vectoriales. Ejemplos: Azure SQL, PostgreSQL/pgvector o en NoSQL MongoDB. Son útiles para consolidar datos, pero son menos especialización que una vector DB dedicada.
 - Bases de datos gráficas con funciones vectoriales: grafos como Neo4j que añaden búsqueda vectorial. Permiten combinar re-

laciones explícitas (grafos) con similitud semántica (vectores). Ejemplos: path finding sujeto a similitud.

Cuando la recuperación se externaliza, es decir, cuando la búsqueda y obtención de información no la realiza el sistema sobre su propia base vectorial, sino que se delegan en un tercero (como por ejemplo una API) o en el documento que aporta el usuario, no es imprescindible construir un *pipeline* de indexación ni mantener una base vectorial. En cambio, en un RAG clásico, donde el sistema recupera conocimiento de su repositorio interno, sí se recomienda diseñar el *pipeline* de indexación y mantener una base vectorial propia [2].

***Pipeline* de Generación (*online*)**

Gestiona la consulta del usuario de extremo a extremo. Este *pipeline* recibe la pregunta del usuario, recupera el contexto relevante de la base vectorial, los *chunks*, aumenta el *prompt* con ese contexto y genera la respuesta con el LLM. Se compone de tres fases: *retrieval*, *augmentation* y *generation* [2].

Los componentes clave del *pipeline* de generación son:

- **Retriever**: es el motor de búsqueda sobre la base vectorial, es decir, la base de conocimiento. Devuelve los documentos más relevantes. Es crítico para la precisión del sistema y contribuye a la latencia, su calidad condiciona el rendimiento del RAG. El método más frecuente son los *embeddings* gracias a su capacidad semántica.
- **Gestión del Prompt (*Augmentation*)**: combina la consulta y el contexto recuperado. Además, aplica estrategias de ingeniería de *prompt* para maximizar la calidad de la respuesta. Las estrategias recomendadas son:
 - *Contextual prompting*: consiste en instruir al modelo para que solo responda con el contexto proporcionado.
 - *Controlled generation prompting*: consiste en indicarle al modelo que no conteste si el contexto no permite responder a la pregunta.
 - *Few-shot prompting*: consiste en incluir ejemplos para forzar el formato de la respuesta.
 - *Chain-of-Thought*: consiste en pedir pasos intermedios cuando los razonamientos son complejos.
- **Configuración LLM (*Generation*)**: es la selección del modelo que va a generar la respuesta final. Pueden ser modelos:

- Originales o *fine-tuned*: los originales facilitan un arranque rápido, mientras que los *fine-tuned* mejoran la adaptación de dominio, la integración del contexto y formato de salida.
- Abiertos o propietarios: los abiertos ofrecen control y despliegue flexible, mientras que los propietarios simplifican el uso y el mantenimiento.
- Tamaño del modelo: los grandes tienen un razonamiento mejor y un contexto más amplio. Los pequeños tienen un coste y latencia menor.

Capas de soporte

Además de los dos *pipelines*, un sistema en producción requiere orquestación, evaluación y monitorización continua, cache semántico para reducir coste y latencia, controles de seguridad para cumplimiento normativo y seguridad frente a inyecciones en el *prompt*, envenenamiento de dato o fugas de información. Todo ello se sostiene sobre una infraestructura de servicio y un RAGOps stack con capas de datos, modelos, *prompting*, evaluación, orquestación, despliegue, hosting y monitorización [2].

3.5. Evaluación de calidad del RAG

Se hará mediante la triada de evaluación propuesta por TruEra [3]. Estructura la calidad en tres comprobaciones entre consulta (*prompt*), contexto recuperado y respuesta. Complementariamente, se emplean métricas como relevancia, precisión y *recall*, y conjuntos ground truth para validación objetiva y monitorización continua en producción [2].

Las tres dimensiones de la triada son:

- Relevancia del contexto: la información que hemos recuperado tiene que ver con la pregunta.
- Groundedness o fidelidad: la respuesta que da el LLM se basa de verdad en el contexto que le hemos dado, sin alucinaciones ni omisiones clave.
- Relevancia de la respuesta: la respuesta es útil y adecuada respecto a la intención y el contexto de la consulta original.

3.6. *Web Scraping*

Web Scraping es el proceso automatizado de extraer información expuesta en páginas web y transformarla en datos estructurados. Se realiza mediante programas que descargan y analizan el HTML o emulan la navegación de un usuario con un navegador controlado por código. Se apoya en técnicas de rastreo (*crawling*), *parseo* y normalización para preparar el dato para su análisis o integración en sistemas [4].

4. Técnicas y herramientas

4.1. Metodologías

Scrum

La metodología Scrum es un marco de trabajo ágil orientado a la gestión y desarrollo de proyectos de manera iterativa e incremental. Se organiza en ciclos cortos denominados *sprints*, al final de los cuales se entrega un incremento funcional del producto. Estos *sprints* favorecen la mejora continua y la adaptación al cambio, además, aseguran una entrega temprana de valor. A diferencia de metodologías tradicionales, Scrum aporta mayor flexibilidad y retroalimentación constante [5].

4.2. Repositorio

Para alojar el repositorio se han valorado distintas alternativas como [Bitbucket](#), [GitHub](#), [GitLab](#) o [Trello](#). Finalmente se ha elegido GitHub que es una plataforma basada en la nube que permite alojar repositorios de código. GitHub ofrece funciones muy útiles como ramas (*branches*), *pull request*, seguimiento de cambios (*commits*), historial del proyecto, gestión de incidencias (*issues*). Además, permite la colaboración entre usuarios, lo que es muy útil para la revisión del proyecto.

Otra ventaja es que GitHub se integra con herramientas de integración y despliegue continuo, lo que facilita la automatización de pruebas y la entrega de *software*. Asimismo, permite incluir documentación directamente en el repositorio, ya sea mediante archivos *README* o a través de *Wikis*, lo que mejora la claridad y la reproducibilidad del trabajo. Finalmente, al tratarse

de la plataforma más utilizada a nivel mundial, cuenta con abundante documentación, lo que la convierte en una alternativa sólida y con amplio soporte [1].

4.3. Gestión de tareas

Para la gestión de las tareas del proyecto se han valorado diversas herramientas, como [ZenHub](#), [GitHub Projects](#) o [Asana](#). Al final se ha optado por usar ZenHub que es una herramienta de gestión de proyectos fácilmente integrable con GitHub. Se ha elegido porque tiene mayor funcionalidad que GitHub Projects. Ambos permiten hacer tableros Kanban para organizar las tareas (*to-do*, *in progress*, *doing*). Pero, ZenHub, además, permite asignar *story points* a las tareas y generar los gráficos *burndown* de los *sprints*.

4.4. L^AT_EX

Editores

Para la edición de los documentos en L^AT_EX se ha considerado usar [T_EXMaker](#), [T_EXStudio](#), [Visual Studio Code](#) y [Overleaf](#). Finalmente se ha optado por usar T_EXMaker, ya que es un editor multiplataforma, gratuito y de código abierto. Tiene un visor PDF integrado, así como herramientas para gestionar la bibliografía mediante BibT_EX. Además, tiene una interfaz simple que facilita el aprendizaje, incorpora funciones como el autocompletado, el plegado de código y la detección de errores de compilación, sin necesidad de instalar complementos adicionales.

Distribución

Como distribución L^AT_EX para procesar los documentos .tex se ha valorado el uso de [MikT_EX](#) y [T_EXLive](#), al final se ha elegido usar MikT_EX ya que permite realizar una instalación mínima e ir añadiendo automáticamente los paquetes necesarios durante la compilación. Además, presenta un buen soporte para Windows, lo que se adapta bien a mi entorno de trabajo [6].

4.5. Web Scraping

Para el *web scraping* se ha valorado usar [Beautiful Soup](#), [Selenium](#), [Playwright](#) y [Requests](#). Finalmente se ha elegido usar

5. Aspectos relevantes del desarrollo del proyecto

Este apartado pretende recoger los aspectos más interesantes del desarrollo del proyecto, comentados por los autores del mismo. Debe incluir desde la exposición del ciclo de vida utilizado, hasta los detalles de mayor relevancia de las fases de análisis, diseño e implementación. Se busca que no sea una mera operación de copiar y pegar diagramas y extractos del código fuente, sino que realmente se justifiquen los caminos de solución que se han tomado, especialmente aquellos que no sean triviales. Puede ser el lugar más adecuado para documentar los aspectos más interesantes del diseño y de la implementación, con un mayor hincapié en aspectos tales como el tipo de arquitectura elegido, los índices de las tablas de la base de datos, normalización y desnormalización, distribución en ficheros³, reglas de negocio dentro de las bases de datos (EDVHV GH GDWRV DFWLYDV), aspectos de desarrollo relacionados con el WWW... Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

6. Trabajos relacionados

Este apartado sería parecido a un estado del arte de una tesis o tesina. En un trabajo final grado no parece obligada su presencia, aunque se puede dejar a juicio del tutor el incluir un pequeño resumen comentado de los trabajos y proyectos ya realizados en el campo del proyecto en curso.

7. Conclusiones y Líneas de trabajo futuras

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas. Además, resulta muy útil realizar un informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- [1] GitHub Inc. Acerca de github y git. <https://docs.github.com/es/get-started/start-your-journey/about-github-and-git>, 2025. [Online; Accedido 22-Septiembre-2025].
- [2] Abhinav Kimothi. *A Simple Guide to Retrieval Augmented Generation*. Manning Publications, July 2025. ISBN 9781633435858. [Consultado 8-Septiembre-2025 a 26-Septiembre-2025].
- [3] Lofred Madzou. What is the rag triad? <https://truera.com/ai-quality-education/generative-ai-rags/what-is-the-rag-triad/>. [Online; Accedido 24-Septiembre-2025].
- [4] Columbia University Mailman School of Public Health. Web scraping. <https://www.publichealth.columbia.edu/research/population-health-methods/web-scraping>, -. [Online; Accedido 28-Septiembre-2025].
- [5] Ken Schwaber and Jeff Sutherland. The scrum guide. <https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-US.pdf>, 2020. [Online; Accedido 22-Septiembre-2025].
- [6] Joseph Wright. Tex on windows: Miktex or tex live? *TUGboat*, 33(1): 53, 2012. URL <https://www.tug.org/TUGboat/tb33-1/tb103wright.pdf>. [Online; Accedido 22-Septiembre-2025].